Neural Computing and Applications (2022) 34:12527–12557
https://doi.org/10.1007/s00521-022-07292-4

REVIEW

머신 러닝을 이용한 EEG 기반 뇌-컴퓨터 인터페이스에서 인간의 감정 인식: 포괄적 검토

에삼 H. 후세인[1] · 아스마 하마드[1] · 압델마이드 A. 알리[1]

수신: 2021년 11월 5일 / 승인: 2022년 4월 11일 / 온라인 게시: 2022년 5월 7일

추상적인
인공 지능의 하위 범주인 감정 컴퓨팅은 인간의 감정을 감지, 처리, 해석하고 모방합니다. 뇌-컴퓨터 인터페이스(BCI)와 같은 휴대용 비침습적 인간 센서 기술의 지속적인 발전 덕분에 감정 인식은 다양한 분야의 학자들의 관심을 끌었습니다. 얼굴 표정, 음성, 행동(제스처/자세) 및 생리적 신호는 모두 인간의 감정을 식별하는 데 사용할 수 있습니다. 그러나 처음 세 가지는 사람들이 의식적으로 또는 무의식적으로 진정한 감정을 숨길 수 있기 때문에 효과가 없을 수 있습니다(소위 사회적 가면). 생리적 신호는 보다 정확하고 객관적인 감정 인식을 제공할 수 있습니다. 뇌파(EEG) 신호는 실시간으로 반응하며 주변 신경 생리적 신호보다 감정 상태의 변화에 더 민감합니다. 따라서 EEG 신호는 감정 상태의 중요한 특징을 보여줄 수 있습니다. 최근 여러 EEG 기반 BCI 감정 인식 기술이 개발되었습니다. 또한 머신 러닝과 딥 러닝의 급속한 발전으로 머신이나 컴퓨터가 감정을 이해, 인식 및 분석할 수 있게 되었습니다. 이 연구에서는 다중 채널 EEG 신호 기반 BCI에 의존하는 감정 인식 방법을 검토하고 이 분야에서 달성된 사항에 대한 개요를 제공합니다. 또한 감정 상태를 이끌어내는 데 사용된 데이터 세트와 방법에 대한 개요도 제공합니다. 일반적인 감정 인식 경로에 따라 다양한 EEG 특징 추출, 특징 선택/축소, 머신 러닝 방법(예: k-최근접 이웃), 지원 벡터 머신, 의사 결정 트리, 인공 신경망, 랜덤 포레스트, 나이브 베이즈) 및 딥 러닝 방법(예: 장기 단기 메모리가 있는 합성곱 신경망 및 순환 신경망)을 검토합니다. 또한 감정과 강력하게 연결된 EEG 리듬과 특정 뇌 영역과 감정 간의 관계에 대해 논의합니다. 또한 EEG 데이터를 사용하고 다양한 머신 러닝 및 딥 러닝 알고리즘을 비교하는 2015년과 2021년 사이에 발표된 여러 인간 감정 인식 연구에 대해서도 논의합니다. 마지막으로 이 리뷰에서는 EEG를 사용하여 인간의 감정 상태를 인식하고 분류하는 데 있어 여러 과제와 미래 연구 방향을 제안합니다.

키워드 뇌-컴퓨터 인터페이스(BCI) · 감정 컴퓨팅(AC) · 머신 러닝 · 딥 러닝 · 뇌파(EEG) · 감정 인식

1 서론

1.1 뇌-컴퓨터 인터페이스

뇌-컴퓨터 인터페이스(BCI)는 중추 신경계의 신경 활동에서 생성된 신호를 분석하는 컴퓨터 기반 통신 시스템입니다. 이것은 신경근 또는 근육 경로에 의존하지 않고 통신, 명령 및 따라서 행동을 수행하는 매우 효과적인 통신 기술입니다. 의도를 가지고 생각하는 동안 주체는 출력 장치에 대한 명령으로 변환되는 뇌 신호를 생성합니다. 결과적으로 뇌에 새로운 출력 채널이 제공됩니다[1, 2].

✉ Essam H. Houssein
essam.halim@mu.edu.eg

Asmaa Hammad
asmaa.hammad@mu.edu.eg

Abdelmgeid A. Ali
a.ali@mu.edu.eg

[1] Faculty of Computers and Information, Minia University, Minia, Egypt

BCI의 기본 목표는 사용자의 의도를 나타내는 사용자의 뇌 신호의 특징을 감지하고 평가하는 것입니다. 이러한 특징은 그런 다음 사용자의 원하는 의도를 충족시키기 위해 실행되는 외부 장치로 전송됩니다[1]. 그림 1에서 볼 수 있듯이 이 목표를 달성하기 위해 BCI 기반 시스템은 신호 수집, 사전 처리, 변환 및 피드백 또는 장치 출력의 네 가지 순차적인 구성 요소를 갖습니다.

신호 수집은 첫 번째 BCI 구성 요소로, 주로 신경 활동에 의해 생성된 신호를 수신하고 기록하고, 이 데이터를 신호 강화 및 노이즈 감소를 위해 전처리 구성 요소로 전송하는 역할을 합니다. 뇌 신호 수집 방법은 침습적 방법과 비침습적 방법으로 분류할 수 있습니다. 침습적 방법에서는 전극을 신경외과적으로 사용자의 뇌 내부 또는 표면에 배치합니다. 뇌 활동은 비침습적 기술[3]에서 외부 센서를 사용하여 기록합니다. 전처리 후, 중요한 신호의 다양한 특성(예: 사용자의 의도와 연결된 신호의 특성)을 무관한 데이터에서 추출하여 출력 명령어로 변환할 수 있는 방식으로 표시합니다. 이 구성 요소는 개선된 신호에 대한 선택적 기능을 생성하고, 변환 알고리즘으로 전송할 수 있는 데이터의 크기를 줄인 다음, 문자를 외부 장치가 작업을 완료하는 데 필요한 관련 명령어(예: 사용자의 의도를 완료하는 명령어)로 변환합니다. 출력 장치는 변환 알고리즘에서 수집한 명령어에 의해 안내되고 제어됩니다. 알파벳 선택, 마우스 제어, 휠체어 작동, 로봇 팔 이동, 신경 보철물로 마비된 팔다리 이동 등 사용자가 목표를 달성하도록 돕습니다. 컴퓨터는 현재 가장 많이 사용되는 통신용 출력 장치입니다[4].

외부 삽입 전극을 사용하는 뇌파(EEG)는 BCI에 유용한 신경 활동을 측정할 수 있으며 안전하고 저렴하며 비침습적이고 사용이 쉽고 휴대성이 뛰어나며 높은 시간 분해능을 유지합니다[5]. EEG는 기술자나 운영자의 도움 없이 사용자가 다양한 분야의 BCI 시스템에 사용할 수 있기 때문에 최종 사용자 사이에서 인기를 얻었습니다. BCI는 교육, 의학, 심리학, 군사를 포함한 다양한 분야에 기여했습니다[6].

그림 1 BCI 구성요소

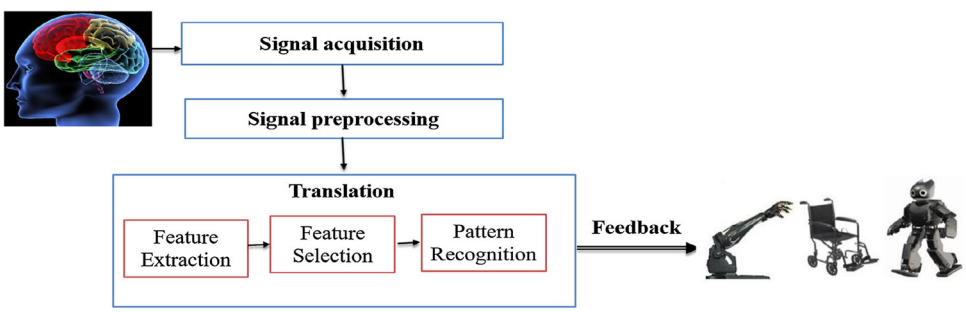

주로 정서적 컴퓨팅 분야와 마비된 개인을 위한 지원 형태로 사용됩니다. 철자 시스템, 의료 신경인간공학, 휠체어 제어, 가상 현실, 로봇 제어, 정신적 작업 부하 모니터링, 게임, 운전자 피로 모니터링, 환경 관리, 생체 인식 시스템 및 감정 감지는 EEG 기반 BCI의 가장 중요한 성공 사례 중 일부입니다[7].

1.2 감정 인식

최근 몇 년 동안 다양한 전자 기기의 가용성이 증가함에 따라 사람들은 소셜 미디어에 더 많은 시간을 보내고, 온라인 비디오 게임을 하고, 온라인 쇼핑을 하고, 다른 전자 제품을 사용하고 있습니다. 그러나 대부분의 현대적 인간-컴퓨터 상호작용(HCI) 시스템은 감정 데이터를 처리하고 이해할 수 없으며 감정 지능이 부족합니다. 이러한 시스템은 인간의 감정을 인식하고 감정 데이터를 사용하여 의사 결정과 조치를 취할 수 없습니다. 고급 지능형 HCI 시스템에서는 인간과 로봇 간의 관계의 부재를 해결하는 것이 중요합니다. 인간의 감정 상태를 무시하는 모든 HCI 시스템은 해당 감정에 적절하게 대응할 수 없습니다. HCI 시스템에서 이러한 어려움을 해결하려면 기계가 인간의 감정 상태를 이해하고 해석할 수 있어야 합니다. 지능형 HCI 시스템 HCI를 실현하려면 신뢰할 수 있고 정확하며 유연하고 강력한 감정 인식 시스템이 필요합니다[8].

HCI는 컴퓨터 과학, 인간 요인 공학, 인지 과학을 포함한 다양한 분야에서 연구되기 때문에 지능형 HCI 시스템을 구동하는 컴퓨터는 적응 가능해야 합니다. 적절한 응답을 생성하려면 인간의 의사소통 패턴을 정확하게 이해해야 합니다. 컴퓨터가 인간의 감정과 행동을 이해하는 능력은 적응력의 중요한 구성 요소입니다. 따라서 HCI 시스템의 성능을 극대화하고 향상시키기 위해 사용자의 정서적 상태를 인식하는 것이 필수적입니다.

HCI 시스템에서 컴퓨터가 실시간으로 인간 작업자의 감정 상태를 정확하게 이해할 수 있다면 기계-작업자 상호작용을 개선하여 더욱 지능적이고 사용자 친화적으로 만들 수 있습니다. 이 새로운

연구 분야는 정서 컴퓨팅(AC)이라고 합니다. AC는 사용자의 정서 감지를 통해 HCI에 초점을 맞춘 인공 지능 분야입니다. AC 도메인의 주요 목표 중 하나는 기계가 인간의 감정을 해석할 수 있는 방법을 만드는 것입니다. 이를 통해 기계의 의사 소통 능력이 향상될 수 있습니다[9].

행동, 음성, 얼굴 표정 및 생리적 신호는 모두 인간의 감정을 식별하는 데 사용될 수 있습니다[10 – 12]. 처음 세 가지 접근 방식은 다소 주관적입니다. 예를 들어, 조사 대상은 의도적으로 진정한 감정을 숨길 수 있으며, 이는 성과에 영향을 미칠 수 있습니다. 생리적 신호를 기반으로 한 감정 식별은 더 신뢰할 수 있고 객관적입니다[13].

BCI는 뇌 신호를 포착하여 감정과 EEG 변화 간의 상관 관계를 이해하는 시스템의 입력으로 사용하여 HCI를 인간화하는 휴대형 비침습 센서 기술입니다[14]. 중추 신경계는 다른 말초 신경 신호보다 감정 변화에 더 빠르게 반응하는 EEG 신호를 생성합니다. 더욱이 EEG 신호가 감정 인식에 필수적인 특징을 제공한다는 것이 입증되었습니다[15].

1.3 감정에 대한 과학적 관점

다음 섹션에서는 감정이 무엇인지, 감정 표현 모델, 감정을 유발하거나 유발하는 실험에 대해 간략하게 논의합니다.

1.3.1 감정이란 무엇인가?

감정은 인간의 인식을 표현하는 복잡한 상태이며 환경 자극에 대한 반응으로 설명됩니다[16]. 감정은 일반적으로 우리 환경에서 발생하는 아이디어, 기억 또는 사건에 대한 반응입니다. 그것은 의사 결정과 인간의 대인 관계 의사 소통에 필수적입니다. 사람들은 감정 상태에 따라 결정을 내리므로 나쁜 감정은 심리적 어려움뿐만 아니라 신체적 어려움으로 이어질 수 있습니다. 불리한 감정은 건강을 해칠 수 있는 반면 긍정적인 감정은 더 높은 생활 수준으로 이어질 수 있습니다[17].

1.3.2 감정 모델

역사적으로 심리학자들은 감정을 특징짓기 위해 두 가지 기술을 사용해 왔습니다. 이산적(기본적) 감정 모델[18]과 차원적 모델[19]입니다. 차원적 모델은 차원 또는 척도에 따라 감정을 분류하고, 이산적 감정 모델은 여러 가지 주요 감정으로 구성되며 두 가지 감정 범주(긍정적, 부정적)를 포함합니다. 여러 이론가들이 기본 감정을 식별하기 위해 실험을 수행했으며 여러 가지 분류된 모델을 제시했습니다. 다윈[20]은 나중에 톰킨스[21]가 해석한 감정 이론을 제안했습니다. 톰킨스는 이산적인 감정은 9가지 기본 감정으로 구성되어 있습니다: 관심-흥분, 놀라움-놀람, 즐거움-기쁨, 괴로움-고통, 냄새, 두려움-공포, 분노-격노, 경멸-혐오, 수치-굴욕. 이 9가지 기본 감정은 최적의 정신 건강에 중요한 역할을 한다고 믿어집니다.

Ekman 모델[22]은 또 다른 널리 받아들여진 이론을 기반으로 합니다. Ekman에 따르면 기본 감정은 다음과 같은 특성을 포함해야 합니다. (1) 감정은 본능적입니다. (2) 다양한 사람들이 동일한 상황에서 동일한 감정을 발달시킵니다. (3) 다양한 사람들이 기본 감정을 비슷한 방식으로 표현합니다. (4) 다양한 사람들의 생리적 패턴은 기본 감정이 생성될 때 일정합니다. Ekman과 그의 동료들은 얼굴 표정으로 보편적으로 인식할 수 있는 여섯 가지 기본 감정이 있다고 결정했습니다. 슬픔, 놀라움, 행복, 혐오감, 두려움, 분노입니다. 수줍음, 죄책감, 경멸과 같은 다른 복합(비기본) 감정은 이러한 여섯 가지 기본 감정에서 생성될 수 있습니다. 많은 이론가와 심리학자는 Ekman의 여섯 가지에 포함되지 않은 추가 감정을 기본 감정 세트에 포함시켰습니다. 일부는 감정을 작은 그룹[23 – 28]으로 나누어 두려움이나 분노(부정적인 감정) 및 행복이나 사랑(긍정적인 감정)과 같은 일반적인 감정에 초점을 맞춥니다. 다른 사람들은 더 미묘한 뉘앙스에 초점을 맞추고 감정을 더 큰 그룹으로 나누었습니다. 표 1은 가장 기본적인 감정 모델 중 일부를 요약한 것입니다.

그러나 일부 이론가와 연구자는 이산 모형이 더 광범위한 감정 상태에 걸쳐 특정 감정을 표현하는 데 한계가 있다고 믿습니다.다시 말해, 일상적인 감정 상태는 소수의 이산 범주로 잘 표현하기에는 너무 복잡합니다. 그 결과, 차원적 감정이라는 새로운 방법이 제안되었습니다.이 모델에서 감정은 다차원 방식으로 구성되며 각 차원은 감정적 특성을 나타냅니다.각 감정은 다차원 공간의 점으로 표현될 수 있습니다.이산적 레이블을 선택하는 대신 주의-거부 또는 쾌락-불쾌함과 같이 다양한 연속적 또는 이산적 값의 척도로 감정을 표현할 수 있습니다.현재까지 연구자들은 감정을 모델링하는 수많은 다차원 기술을 제안했습니다.다음은 몇 가지 예입니다.(a) 각성 및 가치 차원을 사용하여 최대 150개의 감정 레이블을 포함할 수 있는 러셀의 순환 2D 모델[19]; (b) 평가 및 활성화를 차원으로 하는 Whissell의 연속 2차원 공간[34]; (c) 2차원 모델에 주의 거부 차원을 추가한 Schloberg의 3차원 감정 모델[35].

러셀의 2D 감정 모델이 가장 많이 사용됩니다. 그림 2에서 보듯이, 수직축은 각성 차원(경험의 감정적 강도를 표현, 낮음에서 흥분까지)을 나타내고, 수평축은 가치 차원(

표 1 분류된 감정 모델 요약

Reference	Emotions
[21]	Surprise, joy, interest, rage, disgust, fear, anguish, shame
[22]	Fear, sadness, happiness, anger, disgust, surprise
[23]	Rage and terror, anxiety, joy
[24]	Pain, pleasure
[25]	Fear, love, rage
[26]	Fear, grief, love, rage
[27]	Expectancy, rage, fear, panic
[28]	Sadness, happiness
[29]	Anger, courage, aversion, dejection, despair, desire, fear, hope, hate, sadness, love
[30]	Happiness, sadness, fear, anger, disgust
[31]	Desire, interest, happiness, surprise, sorrow, wonder
[32]	Anger, disgust, contempt, distress, guilt, fear, interest, shame, joy, surprise
[33]	Anger, fear, elation, disgust

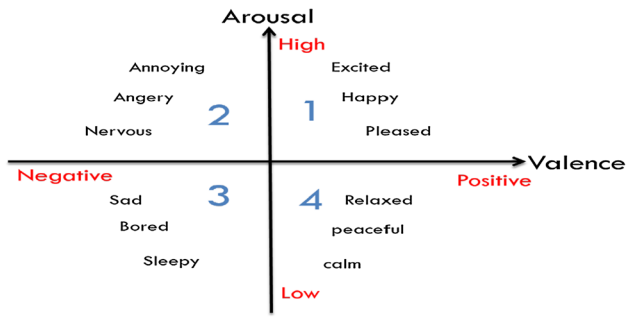

그림 2 2D 감정 모델

영어: 쾌활함이나 기쁨의 정도, 부정적에서 긍정적까지).각성-가치 좌표계에는 네 가지 범주의 감정이 있습니다.부정적 감정은 좌표의 왼쪽에 표시되고 긍정적 감정은 오른쪽에 표시됩니다.가치 축은 긍정적 감정과 부정적 감정을 모두 나타내며, 각성 축은 비활성적 감정에서 활성적 감정까지 다양합니다.그림 2는 기쁘기에서 흥분까지 다양한 높은 각성 긍정적 가치(HAPV) 감정으로 구성된 첫 번째 영역을 보여줍니다.영역 2는 긴장에서 성가심까지 다양한 높은 각성 부정적 가치(HANV) 감정으로 구성됩니다.영역 3은 낮은 각성 부정적 가치(LANV) 감정으로 구성됩니다.마지막 영역은 낮은 각성 긍정적 가치(LAPV) 감정(차분함에서 이완)을 포함합니다.그림 2에서 볼 수 있듯이 처음 두 영역은 높은 각성(활성) 감정을 반영하는 반면 마지막 두 영역은 낮은 각성(비활성) 감정을 나타냅니다.

1.3.3 감정 유발 모델

실험 대상의 감정 상태를 특정한 적절한 방식, 즉 감정적 각성으로 유도/유도하는 능력은 생리적 신호를 기반으로 한 감정 감지에서 중요한 단계입니다. 이를 위한 세 가지 주요 방법이 있습니다.

감정 유발. 첫째, 시뮬레이션 시나리오를 만들어 감정을 유발합니다. 사람들은 과거에 잊을 수 없는 감정을 일으키는 습관이 있습니다. 피험자에게 뚜렷한 감정적 색채가 있는 과거 경험의 단편을 회상하게 하여 감정을 유발하는 것도 가능합니다. 이 접근 방식의 문제점은 피험자가 일치하는 감정을 생성할 것이라는 보장이 없고 연관된 감정의 시간은 헤아릴 수 없다는 것입니다. 둘째, 비디오, 음악, 사진 및 기타 자극적인 자료를 표시하여 감정을 유발합니다. 이것은 감정을 유발하고 참가자가 감정 상태를 생성하고 객관적으로 레이블을 지정하도록 하는 빈번한 접근 방식입니다. 마지막으로 피험자는 컴퓨터 또는 비디오 게임을 해야 합니다. 컴퓨터 게임은 신체적으로 유익할 뿐만 아니라 심리적으로도 유익합니다. 피험자는 단편 영화나 클립을 사용하는 동안 환경의 소리를 듣고 볼 뿐입니다. 반면에 컴퓨터 게임의 피험자는 자극을 관찰하거나 보는 데 그치지 않고 실제로 장면을 직접 실험합니다. 그들은 게임 캐릭터의 롤모델을 채택하는데, 이는 개인의 감정에 비슷한 효과를 미칩니다.

감정 유발을 위한 가장 일반적인 리소스는 International Affective Digitized Sound System(IADS)[36]과 International Affective Picture System(IAPS)[37]입니다. 이러한 데이터 세트에는 표준화된 감정 자극이 포함되어 있습니다. 결과적으로 실험 연구에 가치가 있습니다. IAPS는 60개 이미지의 20개 그룹으로 나뉜 1200장의 사진으로 구성되어 있습니다. 각 사진에는 가치와 각성 값이 지정됩니다. 최신 버전의 IADS에는 일상 생활에서 흔히 볼 수 있는 167개의 디지털로 녹음된 자연음이 포함되어 있으며 가치, 지배력, 각성에 따라 분류됩니다. 참가자는 Self-Assessment Manikin 시스템[38]을 사용하여 데이터 세트에 레이블을 지정했습니다. [39]의 저자는 시각적 또는 청각적 자극에 의해 유발된 감정은 비슷하다고 말합니다. 반면에 멀티미디어의 정서적 레이블링 결과는

일상적인 상황이나 더 상호작용적인 상황. 그 결과, BCI 결과의 일반화를 보장하기 위해 상호작용적인 감정 자극을 포함하는 더 많은 연구가 환영받습니다. 우리가 아는 한, 게임을 하거나 비행 시뮬레이터를 사용하는 개인과 같이 감정을 생성하기 위해 더 상호작용적인 상황을 사용한 연구는 극소수에 불과합니다.

1.4 동기 및 주요 기여

이 리뷰의 동기는 연구자들이 기계 학습 방법을 사용하여 EEG 기반 BCI에서 인간의 감정 상태를 정확하고 빠르게 인식하는 속도를 높일 수 있도록 하는 것입니다. 이 리뷰의 목적은 EEG를 사용하여 인간의 감정 상태를 분류하기 위해 기계 학습 및 딥 러닝 접근 방식을 사용하는 문헌의 다양한 연구를 식별하는 것입니다. 따라서 이 연구의 주요 기여는 다음 질문에 대한 답을 찾는 것입니다.

– 감정, 감정 모델, 감정 유발 실험은 무엇인가? – 감정 인식에서 뇌-컴퓨터 인터페이스의 역할은 무엇인가? – EEG 데이터와 인간의 감정 상태 간의 관계는 무엇인가? – 다양한 특징 추출 방법에는 무엇이 있는가? – 다양한 특징 선택 및 감소 방법에는 무엇이 있는가? – 현재 EEG 기반 BCI를 사용하여 인간의 감정 상태를 분류하는 데 사용되는 머신 러닝 및 딥 러닝 기술은 무엇인가? – 분류 모델의 효능을 평가하는 데 사용되는 평가 척도는 무엇인가? – EEG 데이터를 사용한 인간 감정 인식 분야의 최근 연구는 무엇인가? – EEG 데이터를 사용한 인간의 감정 상태 인식에서 해결해야 할 문제점과 앞으로 추구해야 할 연구 방향은 무엇인가?

1.5 종이 구성

이 논문의 구성은 다음과 같다. 1절에서는 뇌-컴퓨터 인터페이스, 감정 인식 및 그 기술의 응용 분야, 다양한 감정 유발 모델에 대한 배경을 설명한다. 2절에서는 감정 형성에 있어서 각 뇌 영역의 역할을 소개하고, EEG 주파수 대역과 EEG 특성을 설명하며, 감정과 EEG 데이터 간의 관계를 조사한다. 3절에서는 EEG 기반 인간 감정 인식 BCI 모델의 구조를 설명하고 EEG 신호 수집, 전처리, 특징 추출, 특징 감소 및 선택, 분류에 대한 개요를 제공한다. 그리고 감정 인식 문제에 대한 성능 평가. 4절에서는 감정 정보를 위한 EEG 데이터의 공개 데이터베이스를 설명하고 딥 러닝 및 머신 러닝 접근 방식에 대한 배경 정보를 제시합니다. 5절에서는 EEG 기반 BCI를 사용하여 인간의 감정 상태를 인식하기 위한 머신 러닝 및 딥 러닝 기술을 분석하는 관련 연구를 소개합니다. 6절에서는 과제와 미래 연구 방향에 대해 다룹니다. 마지막으로 7절에서는 연구 검토를 마무리합니다.

2 감정 및 EEG 신호 개요

이 섹션에서는 EEG와 감정에 대한 개요를 제공합니다. 뇌의 구조와 기능은 섹션 2.1에서 설명합니다. 대뇌 피질은 일반적으로 네 영역으로 구분되며, 각각은 고유한 기능을 수행합니다. 전전두엽 피질(PFC)은 연구에서 감정과 가장 밀접하게 연결되어 있는 것으로 입증되었습니다. 섹션 2.2에서는 뇌파, 그 기원, 주파수 대역 및 특성을 자세히 설명합니다. 섹션 2.3에서는 감정 변화와 EEG 신호 간의 연관성과 감정과 가장 관련이 있는 뇌 영역에 대한 배경 정보를 제공하며, 더 적은 전극을 사용하여 좋은 감정 분류 성능을 달성하는 것을 목표로 합니다.

2.1 뇌의 구조와 기능

소뇌, 대뇌, 뇌간은 인간 뇌의 세 가지 주요 구성 요소입니다. 대뇌피질, 뇌핵, 변연계가 대뇌를 구성합니다. 인지 및 고차원의 감정 기능은 주로 대뇌피질에 의해 제어됩니다. 대뇌피질은 인간 뇌의 가장 바깥쪽 층에 위치하며 두께는 약 1-4mm이고 주로 회백질로 구성되며 그 아래에 백질이 있습니다[40]. 뇌는 중앙에 있는 중앙고랑에 의해 좌우 반구로 나뉩니다. 그림 3[6]에서 볼 수 있듯이 전두엽, 후두엽,

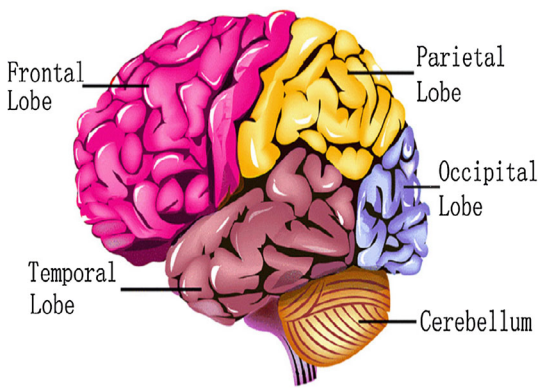

그림 3 대뇌피질의 생리적 구조

두정엽, 측두엽은 대뇌 피질의 네 영역입니다. 이 네 영역의 기능은 구별됩니다. 전두엽은 뇌의 중앙 고랑 앞에 위치합니다. 고등 인지 활동을 담당합니다. 전두엽, 전두엽 운동 영역, 1차 운동 영역은 모두 그 일부입니다. 이들은 주로 계획, 사고, 사람의 감정과 필요와 관련된 생리적 기능을 담당합니다. 중앙 고랑 뒤, 후두엽 바로 앞에 두정엽이 있습니다. 이것은 가장 높은 수준의 감각 센터입니다. 주로 체성 감각 정보의 통합과 통증, 압력, 온도, 맛, 촉감과 같은 공간 정보에 대한 반응을 담당합니다. 이 영역은 또한 논리적 및 수학적 사고와 관련이 있습니다. 측두엽 아래에는 측두엽이 있으며, 전두엽은 앞에, 후두엽은 뒤에, 두정엽은 위에 있습니다. 주로 청각 및 후각 정보 처리를 담당하며, 감정 및 기억(정신 활동)과 관련이 있습니다. 마지막으로 후두엽은 반구 뒤쪽, 후두엽 고랑 뒤에 위치하며, 주로 시각 관련 정보 처리를 담당합니다. 또한 사람의 기억, 행동 인식 및 추상적 개념과 관련이 있습니다.

2.2 EEG 신호

2.2.1 EEG의 역사

뇌는 뉴런 간에 전기 신호를 전달하여 작동합니다. 뇌의 전기적 활동을 연구하는 한 가지 방법은 뇌 활동으로 인해 발생하는 두피의 전위를 기록하는 것입니다. 기록된 신호, 즉 두 위치 간의 잠재적 변화를 뇌파(EEG)라고 합니다. EEG는 종종 뇌파로 알려진 뇌 활동을 모니터링하는 가장 효율적인 방법 중 하나입니다. Hans Berger는 1929년에 최초의 인간 EEG를 기록하고 최초의 인간 EEG 논문을 발표했습니다[41]. 이 분야의 전공자로서 그는 "뇌파"라는 용어를 고안했습니다. 19세기에 Richard Caton이 동물의 뇌 활동에 대해 수행한 초기 연구는 그의 연구의 기초가 되었습니다. 전기 생리학자와 신경 생리학자는 점차적으로 그의 결과를 검증하여 임상 의학과 뇌 과학에서 EEG 연구가 빠르게 발전할 수 있었습니다. 감정의 변화는 EEG 신호를 연구하면 이해할 수 있습니다. 중추신경계(CNS)의 기능적 및 생리적 변화는 신경 전위에 반영될 수 있습니다. EEG는 단일 뉴런의 전기적 활동만을 나타내는 것이 아니라 EEG 측정 전극이 위치한 뇌 영역의 뉴런 그룹의 전기적 활동을 나타냅니다. 결과적으로 EEG 신호에는 유용하고 의미 있는 심리생리학적 정보가 풍부하게 포함됩니다. 의학에서 EEG 신호 분류, 처리 및 분석은 다음을 제공할 수 있습니다.

일부 질병을 탐지하기 위한 객관적인 근거. 신경공학에서 장애인은 모션 이미지나 마인드에서 생성된 EEG 신호를 사용하여 휠체어나 로봇 팔다리를 제어할 수 있습니다. 이는 현재 뇌-컴퓨터 인터페이스(BCI)로 알려진 인기 있는 주제입니다. EEG 신호의 분석 및 처리에는 EEG 데이터의 비정상성과 수많은 환경적 영향으로 인해 뇌 연구에서 항상 문제가 있습니다.

2.2.2 EEG의 기본

EEG 신호는 주파수 대역의 변화에 따라 델타(0.5~4Hz), 세타(4~8Hz), 알파(8~13Hz), 베타(13~30Hz), 감마([30Hz)의 5가지 종류로 분류된다[6].

델타파는 일반적으로 진폭 20~200 lV로 전두엽 피질에서 발생합니다. 일반적으로 산소 부족, 깊고 꿈 없는 수면 또는 마취 상태와 같은 무의식 상태에서 감지됩니다. 이 파동은 깨어 있고 경계하는 성인에서는 사라집니다. 세타파는 일반적으로 진폭 100~150 lV로 두정엽과 측두엽에 나타납니다. 이 파동은 이완 상태와 작업 기억 부하와 관련이 있습니다. 긍정적인 감정이 유발되면 전두엽 중앙선의 세타파가 상승합니다. 알파파는 주로 진폭 20~100 lV로 후두엽과 두정엽에서 발생합니다. 눈을 감고 휴식 상태에서 감지할 수 있습니다. 시각적 또는 청각적 자극과 같은 외부 자극이나 개인이 정신 활동에 참여할 때 알파파가 사라질 수 있습니다. 알파파는 긍정적이고 부정적인 감정 모두에서 베타파와 감마파보다 진동 에너지가 더 큽니다.

베타파는 일반적으로 전두엽에서만 관찰되지만, 사람이 숙고하고 있을 때 베타파는 다양한 위치에서 나타납니다. 진폭은 5~20 lV입니다. 사람의 마음이 매우 활동적이고 집중되어 있을 때 발생합니다. 대뇌 피질은 알파파가 지배하는 반면 인체는 이완되어 있고, 감정 활동이 증가함에 따라 베타 리듬은 점차 사라집니다. 중추신경계가 긴장/스트레스/긴장을 받고 있을 때 알파파의 진폭

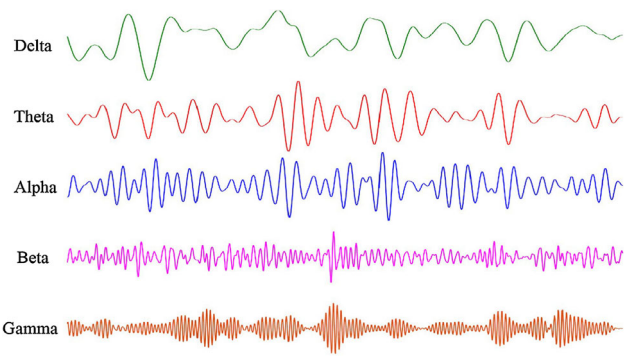

그림 4. 5개 EEG 대역의 파형

감소하는 반면 베타 주파수는 증가하고 알파파는 점진적으로 베타파로 변합니다. 대뇌 피질이 베타 상태로 보일 때는 일반적으로 흥분되었음을 의미합니다. 감마파는 다른 감각 및 비감각 피질 네트워크에서 발견됩니다. 진폭은 일반적으로 2 IV보다 낮습니다. 이들은 정보 수신, 처리, 통합, 전달 및 뇌간의 피드백과 같은 높은 수준의 뇌 인지 과제 및 기능과 많은 주의(집중)를 요구하는 활동과 관련이 있습니다. 이들은 다중 모드 감각 처리 중에 자주 관찰됩니다[5, 6, 8, 13].

2.2.3 EEG 신호 특성

EEG 신호는 뇌 활동을 직접적으로 나타내는 신호로 인간의 뇌 생리현상을 연구하는데 유용하다. 그 주요 특징은 다음과 같다[6, 8].

1. EEG의 기록은 일반적으로 잡음이 많고 환경의 간섭에 민감합니다. 일반적으로 다른 신호(EOG, ECG, EMG 포함), 간섭, 아티팩트 및 잡음과 섞여 있습니다.

2. EEG 신호는 자발적 또는 유발된 것으로 분류할 수 있습니다. 신호 수집 과정에서 다양한 주변 생리적 신호는 불가피하게 자발적 EEG 또는 유발 전위에 영향을 미칩니다. EEG 신호는 인체 조직의 적응이나 생리적 조절로 인해 매우 비선형적입니다.

3. EEG 신호 변화는 불안정하고 외부 환경 변수에 민감하며 강력한 비정상성 속성을 가지고 있습니다. EEG 신호의 특징을 발견하고 인식하기 위해 여러 연구에서 통계 분석 접근 방식을 사용합니다.

4. EEG 신호는 0.5~100Hz의 주파수 범위를 갖지만, 0.5~30Hz의 저주파 범위가 인지와 가장 관련이 있습니다. 연구자들은 보통 이를 다섯 가지 주파수 하위 대역으로 분해하는데, 각각은 고유한 인지 기능에 해당합니다.

EEG파의 두 가지 형태는 일반적으로 자발적인 것과 유발된 것으로 분류됩니다. 신경계는 외부 자극 없이 리드미컬한 전위 변동을 생성하는데, 이를 자발적인 EEG라고 합니다. 유발 전위는 인간 감각 기관의 외부 자극/자극의 결과로 대뇌 피질에서 측정 가능한 전위 변화입니다.

2.3 감정 인식에서의 EEG 신호

우리는 컴퓨터가 감정을 이해하고 인식하도록 가르치기 위해 우리 몸 속의 감정의 근원을 이해해야 합니다. 감정은 잘 알려진 단어를 통해 구두로 표현될 수도 있고, 다음과 같이 비구두로 표현될 수도 있습니다. 음성 톤, 얼굴 표정, 신경계의 생리적 변화를 통해. 얼굴 표정과 목소리는 가짜일 수 있거나 특정 감정의 결과로 간주될 수 없기 때문에 감정을 예측하는 신뢰할 수 있는 지표가 아닙니다. 사용자가 생리적 신호를 제어할 수 없기 때문에 더 정확합니다. 우리 몸의 감정의 근본적인 원천은 생리적 변화입니다. 생리적 변화는 중추신경계(CNS)에 영향을 미치는 변화와 말초 신경계(PNS)에 영향을 미치는 변화의 두 가지 범주로 나눌 수 있습니다. 척수와 뇌가 중추 신경계를 구성합니다. 뇌는 우리 몸의 모든 것을 제어하는 센터이며 전기적 활동의 변화는 다양한 행동과 감정으로 변환됩니다. 뇌파(EEG)는 뇌의 전기적 변화를 측정하는 검사입니다. EEG는 금속 전극과 전도성 매체를 사용하여 두피 표면에서 기록된 교대형 전기 활동으로 설명됩니다[42].

EEG는 뇌의 다양한 생리적 상태에 대한 유용한 정보를 풍부하게 담고 있다. EEG는 감정 상태의 변화에 더 빠르고 민감하게 반응하므로 인간의 감정 상태를 이해하는 데 특히 귀중한 도구이다. 저주파 영역은 고주파 대역보다 감정적 EEG를 더 충분히 불러일으키고, 부정적인 감정은 긍정적인 감정보다 더 널리 퍼져 있고 강렬하다[6]. 기쁨, 슬픔, 공포와 같은 감정이 존재할 때 뇌 중앙선의 베타, 알파, 세타파의 평균 파워는 극적으로 다를 것이며, 이는 EEG의 중앙선 파워 스펙트럼이 감정 분류의 가장 유용한 특징 중 하나임을 나타낸다[43].

생리학적 연구에 따르면 인간의 고등 감정 인지 기능은 주로 대뇌 피질에 의해 제어됩니다. EEG 기반 감정 감지를 통해 감정과 밀접하게 관련된 뇌 영역을 찾는 것이 유익할 것입니다[44]. 전극은 먼저 대뇌 피질의 위치에 따라 분류됩니다. 각 전극 그룹의 EEG 특징을 추출한 다음 감정 분류를 수행합니다. 특징 선택 알고리즘은 모든 전극을 중요도에 따라 정렬/순위를 매긴 다음 뇌 지형도를 사용하여 전극의 중요성을 설명하여 순위가 높은 전극이 분포된 뇌 영역을 더 쉽게 인식할 수 있습니다.

EEG를 기반으로 기능적 뇌 연결성을 연구하는 일부 연구자들에 따르면 감정 상태와 뇌의 특정 영역 사이에 상관 관계가 있습니다. Ekman과 Davidson[45]에 따르면 뇌의 좌측 전두엽 부분은 즐거움에 의해 활성화됩니다. 기능적 연결 네트워크는 [46]에서 저자들에 의해 국소적 활성화와 통합되어 감정에 반응하고 이를 반영하는 뇌의 국소적 부분의 활동을 묘사했습니다.

영어: 중요한 뇌 영역 간의 상호 작용. 또 다른 연구에서는 개인이 두려움 감정을 받아들였을 때 좌측 전두엽 활동이 감소한다는 것을 발견했습니다[47]. 즐거운 감정은 전두엽 중앙선에서 세타대 전력이 증가하는 것과 관련이 있는 반면 불쾌한 감정은 그 반대와 관련이 있습니다[48]. 이러한 연구는 감정의 변화와 해당 EEG 신호의 특성 간의 상관 관계를 보여주는데, 이는 EEG 신호 감정 분류를 연구하는 데 더 유용합니다. 또한 이는 EEG 데이터에서 감정을 감지하기 위한 신경 생리학적 기초를 제공합니다.

3 EEG 기반 BCI 감정 인식 방법론

감정 인식을 위한 EEG 기반 BCI 시스템의 아키텍처는 그림 5에 나와 있습니다. EEG 신호 수집, 전처리, 특징 추출, 특징 선택, 감정 분류 및 성능 평가는 다음 섹션에서 논의될 별도의 프로세스입니다.

3.1 EEG 신호 수집

EEG는 현재 뇌의 전기적 활동을 측정하는 표준 방법으로 보편적으로 받아들여지고 있습니다. 최신 EEG 장비에는 전극 세트, 데이터 저장 장치, 증폭기 및 디스플레이 장치가 포함됩니다. 침습적 및 비침습적 EEG 신호 수집 방법이 있습니다. 침습적 방법에서는 신호 대 잡음 비율과 신호 강도가 모두 높습니다. 전극은 외과적으로 두개골 공동에 이식해야 하며 전극이 뇌 피질을 관통하므로 작동하기 어렵습니다. 비침습적 수집 방법에서는 전극을 피험자의 두피에 부착합니다. 이 방법은 사용하기 쉽고 현대 BCI 연구에서 가장 일반적인 수집 방법입니다. EEG 신호는 두피 전체에 비침습적 전극을 배치하는 저렴한 착용형 EEG 헤드셋과 헬멧을 사용하여 효율적으로 수집할 수 있습니다. 다양한 저렴한 EEG 기반 BCI 장치가 현재 시중에 판매되고 있습니다[49].

연구 목표는 서로 다르기 때문에 감정 인식에 초점을 맞춘 EEG 실험에서는 수집된 EEG 신호가 다르고 전극의 수와 위치도 다릅니다.

대부분의 EEG 감정 실험에는 International 10-20 전극 배치 시스템이 사용됩니다. 전극 수는 6개에서 62개까지 다양합니다. Fig. 6[8]을 기준으로 감정과 관련된 EEG 전극은 대부분 전두엽(빨간색), 두정엽(녹색), 후두엽(파란색), 측두엽(노란색) 및 중앙 영역(사각형)에 분포하는 것으로 나타났습니다. 뇌의 전면 극성, 전두엽, 전두엽, 전면 중앙, 측두엽, 두정엽 및 후두엽 영역은 각각 FP, AF, F, FC, T, P 및 O로 약칭됩니다. 좌반구는 홀수 접미사로 표시되고 우반구는 짝수 접미사로 표시됩니다. 이러한 영역은 감정 생성의 생리적 기반과 정확히 일치합니다. 전극 분포를 조정하면 추출된 특징 차원을 상당히 낮출 수 있습니다. 계산의 복잡성이 줄어들어 실험이 더 간단하고 쉽게 수행될 수 있습니다.

3.2 EEG 신호 전처리

EEG 신호의 전처리는 신호 세척 및 강화와 관련이 있습니다. EEG 신호는 본질적으로 약하고 내부 및 외부 소스의 노이즈에 쉽게 감염될 수 있습니다. 노이즈는 전극이나 인체 자체에서 생성될 수 있습니다. 용어 "아티팩트"는 이러한 노이즈를 말합니다. EEG 전극은 EEG 신호를 기록하는 동안 눈 깜박임과 목 근육에서 발생하는 근전도(EMG)와 같은 원치 않는 전기적 생리적 신호를 수집할 수 있습니다. 피험자가 움직일 때 케이블 움직임과 전극 변위로 인한 동작 아티팩트에 대한 우려도 있습니다. 결과적으로 전처리 단계는 원시 EEG 데이터에서 이러한 아티팩트를 줄이는 데 중요하며, 이는 사후 분류에 영향을 미칠 수 있습니다. 이러한 아티팩트를 삭제해야 하는지 여부는 감정 상태에 대한 필수 정보를 포함하고 감정 감지 시스템의 성능을 향상시킬 수 있으므로 신중하게 평가해야 합니다.

수집된 EEG 신호의 아티팩트를 줄이기 위해 주파수 영역 필터를 사용하여 연구할 EEG의 대역폭을 좁힐 수 있습니다. 고주파 필터, 저주파 필터(전기 엔지니어는 고역통과 및 저역통과 필터라고도 함), 버터워스 필터 및 노치 필터는 가장 자주 사용되는 필터 중 일부입니다. 1~50~60Hz 사이의 주파수는 다음을 사용하여 필터링됩니다.

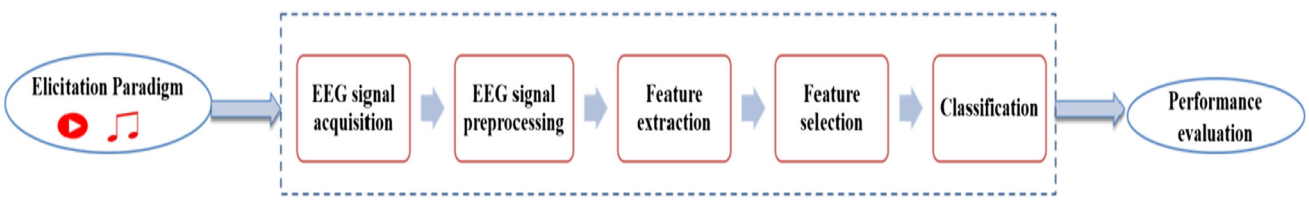

그림 5 감정 인식을 위한 EEG 기반 BCI 시스템의 아키텍처

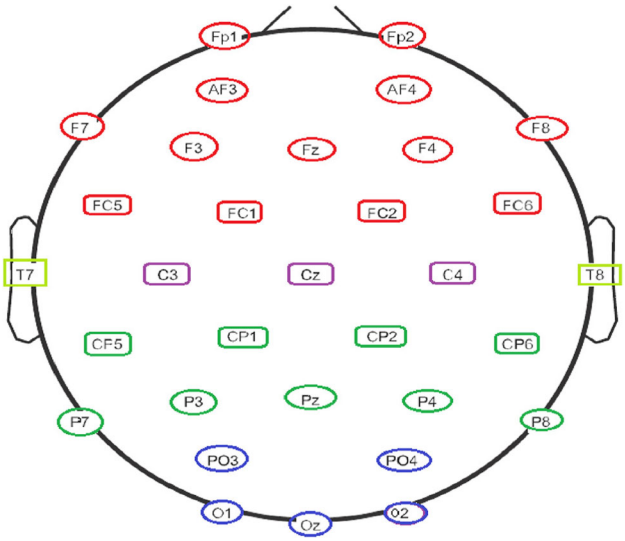

그림 6. 다른 엽의 EEG 기록을 위한 전극

고주파 및 저주파 필터. 버터워스 필터는 넓은 전이 영역과 저지대역 및 통과대역에서 평탄한 반응을 보입니다. 노치 필터는 주파수 범위가 아닌 특정 주파수가 전송되는 것을 방지하는 데 사용됩니다. 노치 필터는 전기 네트워크의 주파수를 제거하는 데 사용되며, 이는 일반적으로 특정 국가의 표준 전기 신호 주파수를 기준으로 50~60Hz 사이에서 다릅니다[13]. 필터를 사용하는 경우 신호 왜곡을 방지하기 위해 주의해서 사용해야 합니다.

다양한 연구에 사용된 EEG 데이터 전처리의 일반적인 방법에는 독립 성분 분석(ICA)[50], 주성분 분석(PCA)[51], 공통 평균 참조(CAR)[52] 및 공통 공간 패턴(CSP)[53]이 있습니다. 다중 채널 녹음을 사용할 때 PCA 및 ICA 도구는 블라인드 소스 분석을 사용하여 소스 신호에서 노이즈를 제거하여 아티팩트를 제거하고 노이즈를 줄이는 데 활용할 수 있습니다. CSP 방법은 근육 운동과 상관관계가 있는 신호를 식별하는 데 사용할 수 있는 공간 필터를 식별합니다. 노이즈 감소를 위해 CAR이 이상적입니다.

감정 및 기준선(비감정적) 상태의 EEG 데이터는 감정 감지를 위한 전처리된 EEG 데이터에 포함됩니다. 더욱이 생리적 신호는 개인 간에 상당한 이질성(즉, 한 사람에서 다른 사람으로의 변화)을 보여줍니다. 다양한 시간 지점 및/또는 다양한 환경에서 피험자와 자극 자료가 동일하더라도 다른 감정이 유발될 수 있습니다. 그 결과, 전처리 방법 중에서 이전 자극 자료가 이어지는 감정 상태에 미치는 영향과 생리적 신호의 개별적 차이의 영향을 줄이기 위해 기준선 EEG(모든 유형의 감정적 자극 이전)의 특징은 EEG의 특징에서 제거되었습니다.

감정적 자극.그런 다음 나머지 기능은 [0, 1] [8] 간격으로 조정됩니다.유사한 자극에 대한 주관적인 감정 반응의 개별 분산은 감정 인식 연구에서 주요 어려움입니다.따라서 대부분의 연구는 제한된 수의 감정 클래스를 갖습니다.DEAP 감정 인식에 대한 많은 연구[54]는 이진(높음 대 낮음 각성 또는 긍정 대 부정) 분류 문제[55 – 59]에 초점을 맞추고 있으며, 대상 감정 레이블은 일반적으로 피험자의 주관적 평가 데이터의 간단한 하드 임계값을 활용하여 결정됩니다.

3.2.1 독립성분 분석

독립 성분 분석(ICA)은 상호 독립성을 극대화하는 관찰 가능한 데이터의 선형 투영을 찾는 통계적 방법입니다[60]. 블라인드 소스 분리(BSS)에 사용될 때 ICA는 다중 채널 관찰을 사용하여 이러한 소스의 혼합에서 독립적인 소스를 복구하려고 합니다. EEG 신호 처리에서 ICA는 다양한 뇌 영역에서 발생하는 신경 독립 소스 활동과 눈 움직임, 깜박임, 심장, 근육 및 라인 노이즈와 관련된 비신경 독립 소스 활동(인공물 구성 요소)으로 신호를 분리합니다. 이는 공간-시간적 특성을 기반으로 쉽게 이해할 수 있습니다[50].

다음은 ICA 문제에 대한 설명입니다. 선형 혼합 모델, m 채널 EEG 신호, X ¼ ½x1; x2; :::xm], n 독립 소스 s ¼ ½s1; s2. . .sn]를 가정합니다. 관찰된 신호 벡터 X는 다음과 같이 표현할 수 있습니다.

$$X = As \tag{1}$$

여기서 A는 m× n 크기의 혼합 행렬입니다. 독립 구성 요소(복구된 소스 신호)의 활동 V는 X에 비혼합 행렬 W(즉, 행렬 A의 역수)를 적용하여 얻었습니다[60].

$$V = WXX = W^{-1}V \tag{2}$$

여기서 W^{-1}의 각 열은 독립 구성요소의 전극 가중치(즉, 공간 투영)를 포함하고 W의 각 행은 독립 구성요소를 추정하기 위한 공간 필터입니다.

ICA 기반 아티팩트 제거에는 세 단계가 포함됩니다. (a) ICA를 EEG 데이터에 적용합니다. (b) 아티팩트 관련 독립 구성 요소를 식별하여 삭제합니다. (c) EEG 관련 독립 구성 요소를 전극으로 다시 투사하여 아티팩트 교정 EEG 데이터를 재구성합니다. 일반적으로 EEG 아티팩트의 시공간적 특성에 대한 사전 지식을 사용하여 아티팩트 독립 구성 요소를 식별할 수 있습니다.

많은 연구에서 ICA가 EEG 인공물을 제거하는 데 우수하다는 것이 입증되었습니다. ICA는 Wang et al. [50]에 의해 운동 중에 기록된 EEG 신호를 교정하는 데 사용되었습니다.

근육과 눈의 움직임이 많은 계획 작업. 근육과 눈의 활동에서 나오는 인공물 구성 요소를 제거한 후, 움직임 방향을 인코딩하는 EEG 신호를 사용하여 의도된 움직임의 방향을 예상할 수 있습니다. 졸음 모니터링 연구[61]에서 ICA 기반 인공물 제거는 여러 신체/머리 움직임으로 구성된 운전 과정에서 기록된 EEG 데이터를 수정하는 일상적인 방법으로 채택되었습니다. 운동 이미지 기반 BCI에서 EMG/EOG 인공물을 줄인 후 시스템 성능(예: 분류 정확도)이 개선되었습니다[62].

3.3 EEG 특징 추출

전처리 및 노이즈 감소 후 다음 단계는 기능을 추출하는 것입니다. 신호에서 노이즈가 제거된 후 BCI는 분류기에 전송될 중요한 기능을 추출해야 합니다. EEG 데이터를 사용하는 감정 인식 프로세스에서 기능 추출의 주요 목표는 개인의 감정 상태를 효과적으로 반영할 수 있는 정보를 얻는 것입니다. 그런 다음 이러한 정보는 감정 분류 알고리즘에 사용될 수 있습니다. 감정 식별의 정확도는 대부분 추출된 기능에 의해 결정됩니다. 따라서 감정 상태의 필수적인 EEG 기능을 추출하는 것이 중요합니다.

기존 EEG 특징 분석은 종종 시간, 주파수 및 시간-주파수 영역에서 수행됩니다. EEG 데이터의 비선형적 특성으로 인해 EEG 신호의 비선형 동역학 분석을 사용하여 보다 심층적인 연구를 수행할 수 있습니다. 이 섹션에서는 감정을 인식하는 데 사용되는 네 가지 EEG 특징 분석 방법인 시간, 주파수 및 시간-주파수 영역과 비선형 특징 분석을 다룹니다.

표 2는 이 리뷰에서 다룬 연구에서 사용된 특징 추출 방법을 보여줍니다.그림 7은 이 리뷰의 많은 연구 논문에서 사용된 특징 도메인의 사용 비율을 보여줍니다.가장 일반적으로 사용되는 특징은 시간-주파수 도메인의 특징(35%)입니다.주파수 도메인 특징은 두 번째(27%)이고 시간 도메인 특징은 세 번째(20%)입니다.또한 원시 데이터(특징 없음)도 사용됩니다(11%).원시 데이터는 딥 러닝 알고리즘의 입력으로 사용됩니다.원시 데이터를 사용하면 정보가 유지되고 감정과 관련된 중요한 신호 특징을 생략할 위험이 제거되기 때문에 허용 가능한 결과가 생성됩니다.비선형 특징도 사용되었습니다(7%).

표 2 이 리뷰에서 다룬 연구에서 사용된 기능 추출 방법(2015-2021)

References	Feature extraction
[63]	WT, SF
[56]	SF, HP, FFT, ShE, SE, KE.
[57, 64–66]	DWT, SF
[67]	STFT, PSD, DE, DASM, ASM, RASM, DCAU
[58]	MSST
[68]	SF, DE
[59]	FFT, HOS, Bispectral
[55]	SF, HP, FD
[69]	graph-theoretical features
[70]	SF, PSD
[71]	Lempel-Ziv complexity, WT, EMD, AE
[72]	FFT, PSD,SF
[73]	HOS
[74]	EMD,SF
[75]	WT, WE, AE, SE, FE
[76]	TQWT,SF
[77]	PSD, SF, DWT
[78, 79]	DE
[80]	VMD, PSD, SF
[81]	DWT, ToC
[82]	DT-CWT,SF, PSD, FD, DE
[83]	DWT, DE, FD, HP,PSD
[84]	EMD
[85]	DE, PSD
[86]	DDE

통계적 특징(SF), 웨이블릿 변환(WT), 요르트 매개변수(HP), 고속 푸리에 변환(FFT), 이산 웨이블릿 변환(DWT), 섀넌 엔트로피(ShE) 스펙트럼 엔트로피(SE), 콜모고로프 엔트로피(KE), 단시간 푸리에 변환(STFT), 파워 스펙트럼 밀도(PSD), 미분 비대칭(DASM), 미분 엔트로피(DE), 합리적 비대칭(RASM), 미분 인과성(DCAU), 비대칭(ASM), 다변량 동기 압착 변환(MSST), 고차 스펙트럼(HOS), 프랙탈 차원(FD), 경험적 모드 분해(EMD), 근사적 엔트로피(AE), 웨이블릿 에너지(WE), 샘플 엔트로피(SE), 퍼지 엔트로피(FE), 변분 모드 분해(VMD), 조정 가능 Q 웨이블릿 변환(TQWT), 3차 누적(ToC), 이중 트리 복합 웨이블릿 변환(DT-CWT), 동적 미분 엔트로피(DDE)

3.3.1 시간 영역 분석

오랫동안 시간 영역 분석은 뇌 활동 연구에 적용되어 왔습니다. 오늘날 시중에 나와 있는 EEG 수집 장비의 대부분은 EEG를 수집합니다.

시간 영역의 데이터. EEG 분석을 위한 시간 영역에는 이벤트 관련 전위(ERP), 히스토그램 분석 방법, Hjorth 특징/매개변수: 활동, 이동성 및 복잡성[87], 고차 교차(HOC)[88, 89], 주성분 분석(PCA)[90], 독립 성분 분석(ICA) 및 이 영역에서 신호의 자기 유사성 및 복잡성을 측정하는 Higuchi의 프랙탈 차원(FD)[91]과 같은 많은 기술이 있습니다. 이러한 기술은 다음에 의존합니다.

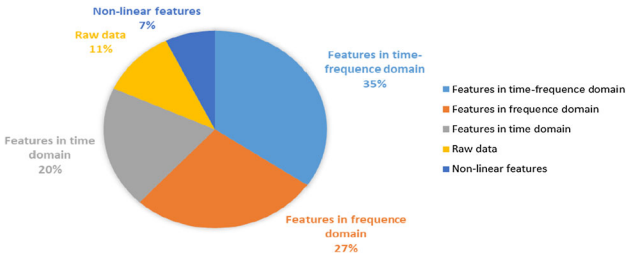

그림 7 이 리뷰에서 논의된 연구에 사용된 기능 도메인의 원형 차트

시간 기반 특징 추출. 또한 평균, 전력, 최대값, 최소값, 중앙값, 표준 편차, 왜도, 분산, 상대 대역 에너지, 첨도 등과 같은 통계적 특징이 있습니다[55, 92]. EEG 신호의 기하학적 특징은 시간 영역 분석의 시작점이며, 이러한 특징은 EEG 분석기를 통해 정밀하고 직관적으로 통계적으로 분석할 수 있습니다. 이 영역의 특징은 정보 손실을 최소화한 EEG 데이터로 구성됩니다. 그러나 EEG 데이터의 복잡한 파형으로 인해 EEG 신호의 시간 영역 특징을 분석하는 공통적인 방법은 없습니다. 따라서 EEG 분석가는 광범위한 전문 지식과 지식을 보유해야 합니다.

3.3.2 주파수 영역 분석

주파수 영역의 특징은 시간 영역의 특징보다 EEG를 사용한 자동 감정 식별에 더 성공적임이 입증되었습니다. 주파수 영역 분석 방법은 주파수 영역 특징을 평가하고 추출하기 위해 시간 영역 EEG 신호를 주파수 영역 신호로 변환합니다. EEG 신호는 일반적으로 다양한 하위 대역으로 구분되고 전력 스펙트럼 밀도(PSD), 대수 에너지 스펙트럼, 고차 스펙트럼(HOS), 차등 엔트로피(DE)와 같은 특징이 분석을 위해 검색됩니다. 주파수 분석을 수행하는 가장 일반적인 방법은 빠른 푸리에 변환(FFT)을 짧은 EEG 세그먼트에 직접 적용하는 것입니다[93, 94].

3.3.2.1 차등 엔트로피 차등 엔트로피(DE)는 고정 길이의 EEG 시퀀스에 대한 특정 주파수 대역의 대수 에너지 스펙트럼입니다[95]. 연속 난수 변수의 복잡성을 평가하기 위한 엔트로피와 마찬가지로 DE는 다음과 같이 표현할 수 있습니다.

$$DE = -\int_{y} f(y)\log(f(y))\mathrm{d}y \tag{3}$$

f(y)는 y의 확률 밀도 함수이며, 여기서 y는 확률 변수입니다. 실험 결과 대역 통과 필터링 후 EEG 신호의 일련의 하위 주파수 대역이 대략 가우스 분포 Nðl; r²Þ를 따르며, 그 차분 엔트로피는 다음과 같이 계산할 수 있습니다.

$$\begin{aligned} DE &= -\int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi\sigma_i{}^2}} e^{-\frac{(y-\mu)^2}{2\sigma_i{}^2}} \log\left(\frac{1}{\sqrt{2\pi\sigma_i{}^2}} e^{-\frac{(y-\mu)^2}{2\sigma_i{}^2}}\right)\mathrm{d}y \\ &= \frac{1}{2}\log(2\pi e\sigma_i{}^2) \end{aligned} \tag{4}$$

3.3.3 시간-주파수 영역 분석

위의 방법들은 각각 EEG의 시간 또는 주파수 영역 특성을 검출 기준으로 사용합니다. 이러한 방법들은 EEG 신호가 선형적이고 준정적이라는 가정에 기초합니다. 즉, EEG 신호의 주파수 내용은 분석 창 동안 일정하다고 가정합니다. 그러나 최근 연구에 따르면 EEG 신호는 비정상적 특성을 가지고 있음이 밝혀졌습니다. 진폭, 지속 시간, 분산 및 자기 상관과 같은 특징을 기반으로 하는 기술을 사용하는 신호의 시간 영역 분석은 성인 EEG 신호와 같은 비정상적 신호를 분석하는 데 적합하지 않습니다. 비정상적 신호를 분석하려면 다양한 주파수에 걸친 에너지 분포와 시간에 따른 주파수 변화에 대한 정보가 필요합니다. 이 정보는 시간 영역 분석 기술이나 주파수 영역 분석에서 제공하지 않습니다. 주파수 영역 표현은 스펙트럼을 형성할 때 모든 시간 정보가 손실된다는 단점이 있습니다. 이러한 제한으로 인해 시간-주파수 영역이라고 알려진 신호를 표현하기 위한 대체 도구가 개발되었습니다.

시간-주파수 영역 분석 기술은 시간 및 주파수 영역의 정보를 결합하여 시간-주파수 영역의 국소 분석을 가능하게 합니다. 결과적으로 시간-주파수 영역 특징은 시간에 따라 변하는 신호와 비정상 신호를 캡처하는 데 적합하며, 이는 다양한 감정 상태를 특성화하는 데 사용할 수 있습니다. 시간-주파수 분석에서 가장 널리 사용되는 접근 방식은 웨이블릿 변환[96]입니다. 단시간 푸리에 변환(STFT)[6], 힐버트 황 변환(HHT)[97] 및 웨이블릿 패킷 변환(WPT)[98]도 필수적인 시간-주파수 영역 분석 접근 방식입니다.

3.3.3.1 웨이블릿 변환 웨이블릿 변환(WT)은 비선형 및 비정상 신호를 처리하기 위한 신호 처리 방법입니다. WT의 중요한 특징은 고주파에서는 완벽한 시간 정보를 제공하고 저주파에서는 완벽한 주파수 정보를 제공한다는 것입니다. 감정 감지 애플리케이션의 신호는 일반적으로 긴 시간 지속 시간을 갖는 저주파 데이터와 짧은 시간 지속 시간을 갖는 고주파 데이터로 구성되기 때문에 이 특성이 중요합니다. 또 다른 이점

웨이블릿 변환의 장점은 다양한 크기의 분석 창을 사용하여 신호의 보다 유연한 시간-주파수 표현을 허용한다는 것입니다. 이를 통해 특징을 추출하는 동안 선택적 분석을 통해 다양한 감정을 인식하고 성능 분류 시스템을 높일 수 있습니다. WT를 사용한 EEG 신호 다중 스케일 분석을 통해 EEG 신호는 다양한 웨이블릿 스케일에서 세부 정보와 근사치를 제공할 수 있습니다. EEG 신호 웨이블릿 분해는 다양한 스케일에서 웨이블릿 계수 세트를 생성합니다. 이러한 계수는 신호의 특성을 완전히 특성화할 수 있으므로 분류를 위한 신호의 특징 세트로 활용할 수 있습니다. 웨이블릿 함수 wðtÞ는 다음과 같이 정의됩니다.

$$\psi(t) = \frac{1}{\sqrt{a}}\psi\left(\frac{t-b}{a}\right) \tag{5}$$

여기서 a와 b는 각각 스케일 인자와 시간 이동으로 표현됩니다. 웨이블릿 변환에는 연속 웨이블릿 변환(CWT)과 이산 웨이블릿 변환(DWT)의 두 가지 유형이 있습니다[99]. CWT가 정의되는 방식은 다음과 같습니다.

$$\mathrm{CWT}(a,b) = \int_{-\infty}^{\infty} x(t)\frac{1}{\sqrt{|a|}}\psi\left(\frac{t-b}{a}\right)\mathrm{d}t \tag{6}$$

여기서 x(t)는 처리해야 할 신호입니다. 스케일과 쉬프트 매개변수를 2의 거듭제곱, 즉 2진 스케일과 위치로 변환하면 웨이블릿 분석이 훨씬 더 효율적일 것입니다. 다음과 같이 표현된 DWT는 이러한 분석을 제공합니다.

$$\mathrm{DWT}(j,k) = \int_{-\infty}^{\infty} x(t)\frac{1}{\sqrt{|2^j|}}\psi(\frac{t-2^j k}{2^j})dt \tag{7}$$

여기서 a와 b는 각각 2^j과 2^jk로 대체됩니다.

3.3.4 비선형 특징 분석

EEG 신호는 매우 복잡하며 비선형적이고 비주기적 특성을 가지고 있어 비선형 동적 분석으로 연구할 수 있습니다. 최근 몇 년 동안 EEG 데이터 분석에 널리 사용되는 많은 비선형 분석 방법이 있습니다[100 – 102]. 비선형 동적 방법에는 순열 엔트로피[103], 근사 엔트로피[104], 특이값 분해 엔트로피, 전력 스펙트럼 엔트로피[105] 및 샘플 엔트로피[106]가 있습니다.

3.4 EEG 특징 선택 및 감소

EEG 기반 감정 인식에서 특징 선택 및 감소 프로세스는 매우 중요합니다. BCI 시스템에서 특징 벡터는 종종 차원이 높습니다[107]. 그 결과, 특징 선택 및/또는 특징 감소 기술이 특징 수를 최소화하는 데 자주 사용됩니다. 이러한 기술은 문제의 복잡성을 단순화합니다. 중요한 정보를 전달하는 기능만 분류기에 전달됩니다. 적절한 기능 선택 및 축소 기술을 선택하면 모델 학습 효율성과 예측 정확도를 모두 높일 수 있습니다.

특징 선택은 특정 유용성 기준에 따라 불필요한(또는 중복된) 특징을 대량으로 효율적으로 제거하여 최소한의 데이터 처리로 최상의 결과를 얻는 기술입니다. 특징 선택 접근 방식은 데이터 세트에 많은 특징이 포함되어 있지만 관찰이 충분하지 않은 경우 과적합의 가능성도 낮춥니다. 특징/차원 감소는 데이터 세트에서 중요한 정보를 추출하여 고차원 데이터를 더 낮은 차원의 이해 가능한 표현으로 변환하려고 합니다[108]. 이상적으로는 축소된 표현에는 데이터의 관찰된 속성을 설명하는 데 필요한 최소한의 매개변수가 포함되어야 합니다[109]. 특징 감소의 중요성은 고차원 데이터 세트를 괴롭히는 차원의 저주를 완화하는 능력에서 비롯됩니다. 일반적으로 특징 선택 및 감소는 데이터 시각화 및 이해를 돕고, 모델 학습 시간을 최소화하고, 차원의 저주를 피하기 위해 필요하며, 이 모든 것이 모델 예측 성능(또는 일반화 가능성)을 개선합니다.

EEG 특징/차원 감소를 위한 일반적인 방법은 주성분 분석(PCA)[110, 111], 선형 판별 분석(LDA)[112] 및 독립 성분 분석(ICA)[112]입니다. PCA는 d차원 데이터를 차원이 낮은 공간에서 표현하려고 시도합니다. 이는 가능성의 범위와 시간과 공간의 복잡성을 제한합니다. 여기서 목표는 제곱합 오차의 관점에서 분산을 정확하게 반영하는 공간에서 데이터를 표현하는 것입니다. 추가 정보는 문헌[112]에서 찾을 수 있습니다. ICA는 다변수이고 무작위적인 신호를 상호 독립적인 구성 요소가 있는 신호로 변환합니다. 혼합 신호에서 이 접근 방식을 사용하여 독립적인 구성 요소를 추출할 수 있습니다. 여기서 독립성은 한 구성 요소가 제공하는 정보를 다른 구성 요소에서 파생할 수 없음을 의미합니다. 자세한 내용은 [112, 113]에 나와 있습니다. LDA의 목표는 원래 예측 변수를 통합하는 새로운 변수를 생성하는 것입니다. 이는 미리 정의된 그룹 간의 새로운 변수의 차이를 최대화하여 수행됩니다. 아이디어는 예측 점수를 판별 점수라고 알려진 단일 새로운 복합 변수로 통합하는 것입니다. 자세한 내용은 [112]에 나와 있습니다.

검색 전략 및 평가 기준은 기능 선택 방법을 분류하는 데 사용할 수 있습니다[114]. 필터와 래퍼라는 두 가지 별개의 기술을 사용하여 선택된 기능의 하위 집합을 평가할 수 있습니다. 필터 방법[115, 116]은 분류 알고리즘에 전달하기 전에 기능을 선택합니다. 즉, 필터 기술

분류 문제에 대한 사전 이해나 데이터에서 얻은 통계에 따라 기능 하위 집합을 선택하고 분류기 설계와 독립적으로 이를 수행합니다. 일반적으로 필터 방법은 훈련 데이터에서 가장 관련성 있는 기능을 선택한 다음 특정 임계값에 따라 특정 기능을 삭제하기 때문에 빠릅니다. 이러한 접근 방식은 계산 비용이 저렴하기 때문에 매우 큰 데이터 세트에 이상적입니다. 래퍼 알고리즘[117, 118]은 분류 알고리즘의 맥락에서(또는 이와 함께) 기능 선택을 실행합니다. 분류기는 이러한 접근 방식에서 선택된 기능 세트를 평가하기 위해 기능 선택 프로세스에서 서브루틴으로 사용됩니다. 이러한 기술은 분류 결과를 대상 함수로 사용하는 일종의 최적화 알고리즘을 나타냅니다. 래퍼 방법은 계산 집약적이기 때문에 정확도를 개선하는 것이 목적인 방대한 데이터 세트에 적용이 제한됩니다. 이 두 가지 방법 외에도 내장된 방법이 딥 러닝과 같은 분류기 알고리즘에서 내부적으로 사용됩니다. 래퍼 메서드는 내장 메서드보다 더 많은 계산이 필요합니다.

표 3은 이 리뷰에서 논의된 연구에서 사용된 특징 선택 및 감소 방법을 보여줍니다. 그림 8은 이 논문에서 검토한 다양한 연구에서 사용된 특징 선택 및 감소 방법의 사용 비율을 보여줍니다. 이러한 연구의 56%는 특징 선택 또는 감소 방법을 사용하지 않습니다. 딥 러닝과 같은 분류 알고리즘에서 내부적으로 작동하는 내장 방법이 자주 사용되며(37%), 그 다음으로 감소 방법(예: PCA 및 ICA), 필터 방법(예: mRMR)(각각 25%), 래퍼 방법(예: PSO)(13%)이 뒤를 잇습니다. 필터에 대한 자세한 내용

표 3 이 리뷰에서 다룬 연구(2015~2021)에서 사용된 기능 선택 및 축소 방법

References	Feature selection/reduction
[63]	PCA
[55, 67]	mRMR
[58]	ICA
[68]	Autoencoder
[59]	BSS
[70]	Welch's t -test with PCA
[72]	LRFS
[73]	CSS
[81]	PSO

주성분 분석(PCA), 최소 중복 최대 관련성(mRMR), 독립 성분 분석(ICA), 역방향 순차 선택(BSS), 지역적으로 견고한 기능 선택(LRFS), 상관 관계 기반 하위 집합 선택(CSS), 입자군 최적화(PSO)

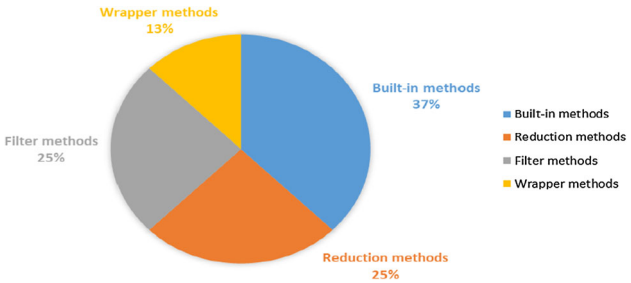

그림 8 이 리뷰에서 논의된 연구에서 사용된 일반적인 EEG 기능 선택 및 감소 방법의 원형 차트

다음 섹션에서는 래퍼 기능 선택 방법을 제공합니다.

3.4.1 필터 방법

필터 방법은 다양한 응용 프로그램에서의 단순성과 성공으로 인해 선택된 다양한 순위 매기기 기술을 사용하여 기능을 정렬합니다.순위 매기기 방법은 관련성에 따라 각 기능을 평가하고 임계값을 사용하여 임계값 아래의 기능을 제거합니다.분류 전에 덜 중요한 변수를 걸러내기 위해 사용되므로 순위 매기기 방법은 필터 방법입니다.변인의 관련성에 대한 다양한 측정 및 정의가 여러 출판물[119, 120]에 제시되었습니다.이러한 정의 중 하나는 "기능이 클래스 레이블과 조건부로 독립적이면 무관한 것으로 간주된다"는 것입니다.기능의 관련성은 상호 정보(MI) 기술의 피어슨 상관 계수와 같은 다양한 기술로 측정됩니다[121].일부 연구자들은 필터링 방법을 적용하여 다양한 감정을 구별하는 데 가장 관련성 있는 기능을 찾았습니다[105]. 대부분의 필터링 알고리즘은 단변량적이므로 각 입력 기능을 개별적으로 고려하므로 각 기능을 자체 평가하고 다른 기능과 독립적으로 사용할 수 있습니다. 이로 인해 두 가지 문제가 발생할 수 있습니다. 개별적으로 관련이 없기 때문에 삭제된 기능은 다른 기능과 결합하면 관련이 생길 수 있으며 개별적으로 관련이 있다고 간주되는 기능은 불필요한 중복을 초래할 수 있습니다. 가장 널리 사용되는 필터 방법은 웨이블릿 변환입니다.

3.4.1.1 최소 중복성 최대 관련성 최소 중복성 최대 관련성(mRMR)은 계산적으로 빠른 것으로 입증된 필터 기반 기능 선택 알고리즘입니다[122]. mRMR의 주요 목표는 다른 기능과 최소 중복성을 갖지만 대상 클래스와 최대 관련성을 갖는 주어진 샘플의 기능 공간에서 기능의 하위 집합을 찾는 것입니다. MRMR 알고리즘은 상호

정보입니다. 최대 관련성과 최소 중복성이라는 두 가지 원칙에 기반합니다. 최대 관련성은 다음과 같이 정의됩니다.

$$D = \frac{1}{|S|}\sum_{x_i \epsilon S} I(x_i, c) \tag{8}$$

여기서 S는 피처 세트를 의미하고 Iðx$_i$; cÞ는 피처 i와 대상 클래스 c 사이의 상호 정보를 의미합니다. 피처 간의 최소 중복성은 다음과 같이 계산됩니다.

$$R = \frac{1}{|S|^2}\sum_{x_i, x_j \epsilon S} I(x_i, x_j) \tag{9}$$

여기서 Iðx$_i$; x$_j$Þ는 특징 i와 j 간의 상호 정보를 의미합니다.

우리는 Eqs. 8과 9를 결합하여 mRMR 방법에 대한 특징 선택 기준을 얻을 수 있습니다.

$$max(D - R) \tag{10}$$

3.4.2 래퍼 메서드

순차적 선택 알고리즘과 휴리스틱 검색 알고리즘은 두 가지 유형의 래퍼 방법입니다. 순차적 선택[123, 124] 알고리즘은 빈 집합으로 시작하여 목적 함수/분류의 최대 성능이 달성될 때까지 기능을 추가합니다. 선택 프로세스를 신속하게 진행하기 위해 가능한 가장 적은 기능으로 최대 성능이 달성될 때까지 목적 함수를 점진적으로 개선하는 기준을 선택합니다. 휴리스틱 검색 알고리즘은 다양한 하위 집합을 평가하여 목적 함수를 향상시킵니다. 기능 선택에서 최적의 하위 집합을 검색하는 것이 중요합니다. 휴리스틱 검색 접근 방식이 최적의 하위 집합을 찾을 수 있다는 것을 보장하지는 않지만 일반적으로 합리적인 시간 내에 만족스러운 답을 발견합니다[125]. 특정 문제를 해결하기 위해 생성된 특정 휴리스틱과 다양한 문제를 처리하기 위해 개발된 범용 메타휴리스틱은 두 가지 유형의 휴리스틱 방법입니다[125]. 메타휴리스틱은 지난 20년 동안 엔지니어링 설계, 데이터 마이닝 스케줄링, 머신 러닝 분야에서 어렵고 대규모 과제를 처리하는 데 효율적이고 효과적임을 입증했습니다.

자연에서 영감을 받은 알고리즘의 대부분은 메타 휴리스틱입니다[126]. 진화 기반(예: 인공 면역 시스템 및 진화 알고리즘), 군집 기반(예: 입자 군집 최적화, 개미 집단 및 벌 집단) 및 물리 기반(예: 시뮬레이트된 어닐링)은 세 가지 주요 영감의 원천입니다[125]. 검색 공간 탐색과 발견된 최적 솔루션의 활용은 이러한 모든 기술이 공통적으로 갖는 두 가지 역설적인 기준입니다[125]. 군집 지능에서 영감을 받은 최적화 기술은 지난 10년 동안 인기가 증가했습니다. 새 무리, 사회적 곤충 및 물고기 무리는 모두 이러한 기술의 모델입니다. 이러한 접근 방식이 기존 기술에 비해 갖는 장점은 유연성과 견고성입니다. 이러한 특성 때문에 군집 지능은 더 복잡한 문제를 해결하는 알고리즘에 대한 성공적인 설계 모델입니다.

최근 새로운 진화 알고리즘이 제시되었고, 기능 선택의 과제에 관해서 많은 응용 프로그램에서 좋은 성능을 보였습니다. [127]에서 Ant Lion Optimizer(ALO)가 이 문제를 해결하기 위한 기능 선택 래퍼 모델로 사용되었습니다. [128]에서 Grey Wolf Optimizer(GWO)가 기능 선택 문제를 해결하는 데 효과적으로 사용되었습니다. [129]에서 저자는 기능 선택을 위해 얼굴 표정 기반 감정 인식에서 입자 군집 최적화(PSO)를 사용했습니다. 또한 [130]에서 저자는 모터 이미지 EEG 신호 분류를 위한 래퍼 기반 기능 선택 알고리즘으로 차등 진화(DE) 알고리즘을 사용했습니다.

3.5 EEG 감정 분류

EEG 데이터 수집, 전처리, 특징 추출, 특징 선택 또는 감소, 그리고 감정 분류는 모두 감정 인식 모델을 구축하는 과정의 단계입니다. 성공적인 감정 분류 시스템을 개발하는 데 가장 중요한 측면 중 하나는 다양한 감정을 정확하게 분류할 수 있는 최상의 분류기를 찾는 것입니다. 개발된 분류기는 감정 인식 정확도에 중요한 영향을 미칩니다[131]. 분류기는 검증 데이터 세트에서 알려지지 않은 관찰의 실제 클래스를 예측하는 수학적 함수에 의존합니다. 다양한 분류 방법이 감정 컴퓨팅 도메인에서 감정 EEG 데이터를 분류하는 데 사용되었습니다. 이러한 분류기는 지원 벡터 머신 및 의사 결정 트리와 같은 기존 분류기(전통적인 머신 러닝 알고리즘)부터 선형 판별 분석, 순환 신경망 및 장단기 메모리와 같은 고급 분류기(딥 러닝 알고리즘)까지 다양합니다.

3.6 성과 평가

감정 인식에 대한 연구 결과는 다양한 연구 그룹이 이해하고 비교할 수 있도록 일관된 방식으로 제시되어야 합니다. 결과적으로 평가 기술을 신중하게 선택하고 지정하는 것이 중요합니다[132]. 혼동 행렬과 정확도는 감정 분류기의 성과를 평가하는 데 가장 권장되는 성과 평가 척도입니다. 혼동 행렬을 기반으로 특이성, 재현율(민감도), 정밀도, F-측정 및

곡선 아래의 면적(AUC)은 일반적으로 계산됩니다. 일반적으로 이러한 측정은 이진 분류 결과(긍정/부정), 정확하게 식별된 감정 상태를 나타내는 참 양성(TP) 및 참 음성(TN)과 감정 상태를 잘못 식별하는 거짓 양성(FP) 및 거짓 음성(FN)의 네 가지 주요 지표를 기반으로 계산됩니다. 이러한 성과 측정은 다음과 같이 정의됩니다.

정확도(Acc): 이 지표는 얼마나 많은 사례가 올바르게 분류되었는지 측정합니다. 클래스가 균형 잡혀 있다면, 즉 각 클래스에 동일한 양의 샘플이 있다면 잘 작동합니다. Eq. 11로 계산합니다.

$$Acc = \frac{(TP + TN)}{(TP + FN + TN + FP)} * 100 \tag{11}$$

민감도(Sens): True Positive Rate 또는 Recall이라고도 합니다. 분류자가 좋은 결과를 적절하게 분류하는 빈도를 평가합니다. Eq. 12로 정의됩니다.

$$Sens = \frac{TP}{(TP + FN)} * 100 \tag{12}$$

특이성(Spec): 진부정률이라고도 합니다. 분류자가 부정 결과를 올바르게 분류하는 횟수의 백분율을 계산합니다. 결과적으로 거짓 양성률(FPR)은 1-특이성과 같습니다. Spec은 Eq. 13으로 계산할 수 있습니다.

$$Spec = \frac{TN}{(TN + FP)} * 100 \tag{13}$$

정확도(Prec): 이 지표는 정확한 분류의 백분율을 나타냅니다. Eq. 14로 표시할 수 있습니다.

$$Prec = \frac{TP}{(TP + FP)} * 100 \tag{14}$$

F-Measure(F): 정밀도와 민감도의 조화 평균을 나타냅니다. 정밀도가 높을수록 민감도가 낮아지고 그 반대의 경우도 마찬가지이므로 중요합니다. Eq. 15로 측정할 수 있습니다.

$$F = 2 * \frac{(Prec * Sens)}{(Prec + Sens)} \tag{15}$$

AUC: 수신자 조작 특성(ROC) 곡선은 다양한 임계값에서 FPR에 대한 Sens를 그래프로 나타낸 확률 곡선입니다. ROC 곡선은 분류기의 성능을 다양한 유의도에서 나타냅니다. ROC 곡선 아래의 면적(AUC)은 분류기가 참 양성과 참 음성을 얼마나 잘 구별할 수 있는지를 나타내는 ROC 곡선을 요약한 것입니다.

4 기본 및 배경

4.1 EEG 감정 인식 데이터 세트

이 섹션에서는 이 리뷰의 다양한 연구에 사용된 감정 인식을 위한 공개 EEG 데이터 세트에 대한 요약을 제공합니다.표 4는 DEAP, MAHNOB-HCI 태깅, DREAMER, SEED, AMIGOS, SAFE 및 GAMOMA 데이터 세트를 포함하여 7개의 공개 EEG 데이터 세트가 감정 인식에 사용되었음을 보여줍니다.이러한 데이터 세트는 연구에 유용하며 여러 감정 인식 연구에 사용되었습니다.그림 9는 이 리뷰의 연구에 따른 감정 인식에 사용된 EEG 데이터 세트의 비율을 보여줍니다.DEEP와 SEED가 가장 일반적으로 사용됩니다(각각 51%와 19%).다른 연구(17%)는 종종 공개적으로 액세스할 수 없는 자체 데이터 세트를 사용했습니다.DREAMER는 공개적으로 사용 가능한 데이터 세트로 이 리뷰에 7%의 참여율로 나타났습니다.MAHNOB-HCI, GAMOMA 및 AMIGOS는 각각 2%의 참여율로 연구 샘플에 나타났습니다.

4.2 머신러닝 개요

감정 인식 문제는 분류 또는 회귀 문제로 표현될 수 있습니다. 이 구분은 주로 1.3.2절에서 논의된 감정을 표현하는 데 사용된 감정 모델을 기반으로 합니다. 감정은 범주형 표현에서 레이블이 있는 별개의 개체로 표현됩니다. 이산 표현과 대조적으로 차원 모델은 일반적으로 축에 표현되는 정의 기능의 연속 값을 사용하여 감정을 설명하려고 합니다.

5.1절에서 보여준 것처럼 이전 기술의 대부분은 감정 인식을 분류 문제로 취급하여 감정 범주 간 또는 러셀의 2D 감정 모델의 다른 영역 간을 구별하려고 시도합니다. 일반적으로 문헌은 감정 차원 회귀보다 감정 분류에 훨씬 더 많이 기여합니다. 결과적으로 이 섹션에서는 머신 러닝 분류 기술에 집중할 것입니다.

감정을 인식하는 시스템에서 머신 러닝 알고리즘은 EEG 기반 BCI에서 다양한 감정 상태를 분류하는 데 사용되었습니다. 정보 소스로 scopus 데이터베이스를 사용하여 그림 10a는 2012년부터 2021년까지의 머신 러닝 및 EEG 감정 인식 및 분류 연구에 대한 통계를 보여줍니다. 그림 10b는 EEG 감정 인식 연구 분야에서 머신 러닝 분포를 보여줍니다.

인공 지능 제품으로서 머신 러닝은 다음을 구별하는 데 중요한 역할을 했습니다.

표 4 감정적 재평가에 사용되는 공개적으로 사용 가능한 EEG 데이터세트 목록

Dataset	Participants	EEG channels	Emotion elicitation	Emotion states
DEAP [54]	32	32	Music videos	Valence, arousal, dominance and liking
MAHNOB-HCI tagging [133]	27	32	Fragments of videos and images	Arousal and valence rated with the self-assessment manikin to elicitseveral emotions (anxiety, neutral, sadness, amusement, disgust, joy, surprise, anger and fear)
SEED [44, 134]	15	62	Film clips	Positive, negative and neutral
DREAMER [135]	23	14	Film clips	Arousal, valence and dominance
AMIGOS [136]	40	14	short and long videos	Arousal, valence, dominance, liking, familiarity and basic emotions.
SAFE [137]	6	5	Selected sounds from IADS.	Pleasant, happy, frightened and angry
GAMEEMO [64]	28	14	Computer games	Boring, calm, horror and funny

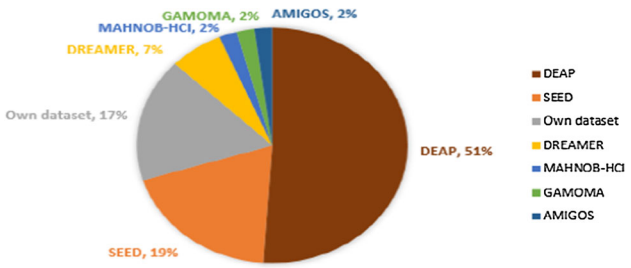

그림 9. 이 리뷰에서 논의된 연구에 사용된 감정 인식을 위한 EEG 데이터 세트의 원형 차트

뚜렷한 뇌 활동 패턴; 따라서 BCI 데이터 분석의 중요한 부분이 되었습니다. 머신 러닝은 소스에서 중요한 지식과 규칙을 학습할 수 있습니다. 작업을 수행한 다음 대상 작업에 적용합니다. 더욱이 머신 러닝 데이터 마이닝 기술은 데이터 관리 시스템에 데이터를 저장하고 머신 러닝 알고리즘을 사용하여 분석하여 잠재적으로 중요한 정보를 추출할 수 있습니다. 선택한 머신 러닝 알고리즘은 최종 분류 또는 예측 결과에 큰 영향을 미칠 수 있습니다[138].

머신 러닝 모델에는 지도 학습과 비지도 학습의 두 가지 범주가 있습니다. 지도 학습은 학습 데이터를 사용하여 분류기의 매개변수를 결정하는 기술입니다. 출력 값을 확인한 후 학습 과제는 유효한 입력 값에 대한 매개변수 값을 설정하는 것입니다. 학습하는 동안 모델에 기여하지 않은 데이터가 포함된 테스트 데이터 세트가 제공됩니다.

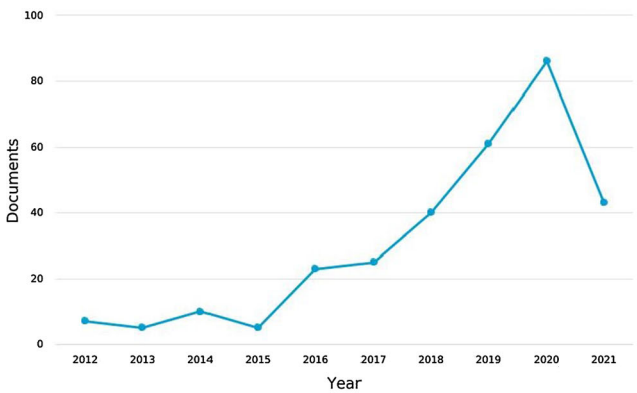

(a) Histogram of machine learning for EEG emotion recognition publications.

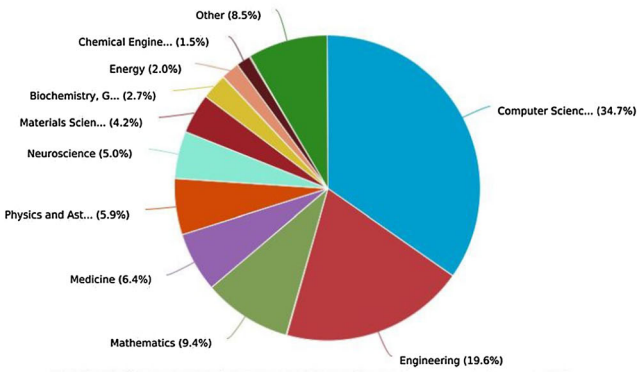

(b) Distribution of machine learning for EEG emotion recognition research area.

그림 10 최근 10년(2012~2021년) 동안 Scopus 데이터베이스를 기반으로 수행된 EEG 감정 인식 연구를 위한 머신 러닝 방법

학습된 알고리즘의 성능을 검증하기 위해 분류기에 넣습니다. 반면, 비지도 학습은 입력 데이터와 줄여야 하는 비용 함수를 기반으로 매개변수를 결정하는 머신 러닝 기법입니다. 최근 몇 년 동안 인간의 감정 인식을 위한 EEG 신호 분류 관리를 위해 여러 ML 모델이 구현되었습니다. 이러한 방법 중에는 널리 분류 방법으로 사용되는 지원 벡터 머신(SVM), 나이브 베이즈(NB), k-최근접 이웃(K-NN), 의사 결정 트리(DT), 랜덤 포레스트(RF) 및 인공 신경망(ANN)이 있습니다. 다음 섹션에서 간략하게 설명하겠습니다.

4.2.1 지원 벡터 머신

지원 벡터 머신(SVM)은 선형 및 비선형 회귀와 분류 문제를 해결할 수 있는 지도 학습 ML 기술입니다. 이를 도입한 사람은 Vladimir Vapnik입니다[139]. SVM은 얼굴 감지 및 인식[140 – 142], 질병 진단[143 – 145], 텍스트 인식[146 – 148]을 포함한 다양한 응용 분야에 사용되었습니다. 일반적으로 SVM은 직관적이고 이론적으로 타당하며 사실상 성공적인 것으로 입증되었습니다.

SVM의 주요 목표는 n차원 데이터의 다양한 그룹(두 개 이상의 클래스)을 정확하게 분리하는 초평면을 찾는 것입니다. SVM은 지원 벡터라고 하는 클래스 설명자의 가장자리에 배치된 훈련 케이스를 기반으로 하며, 다른 모든 케이스는 제거됩니다. 정의한 레이블이나 클래스를 기반으로 SVM은 데이터 포인트 간의 분리 경계를 최대화하려고 합니다. 결과적으로 모든 클래스의 가장 가까운 훈련 포인트와의 거리가 가장 긴 최적의 초평면을 얻어 좋은 피처 분리를 달성합니다. SVM이 데이터를 선형적으로 분리할 수 없는 경우 커널 함수를 사용하여 입력 데이터를 고차원 피처 공간으로 매핑/변환합니다. 고차원 공간에서 선형 분리(낮은 차원 입력 공간에서는 곡면에 해당)를 가능하게 하는 초평면을 설계하는 것이 가능합니다. 결과적으로 SVM에서 커널 함수는 매우 중요합니다. 다항식, 선형 및 가우시안과 같은 커널 함수를 실제로 사용할 수 있습니다.

최적화 알고리즘은 커널 함수 매개변수 r 및 오분류 상쇄 계수 c와 같은 SVM 매개변수에 대한 특정 전역 최적값을 찾는 데 사용할 수 있으며, 이는 최대 마진과 가장 작은 학습 오류 간의 상쇄를 제어합니다. 결과적으로 SVM 기반 분류의 성능은 매개변수 최적화 및 적합한 커널 함수 선택에 의해 결정됩니다. 잘못된 SVM 매개변수 설정은 과적합 또는 과소적합과 같은 잘못된 분류 결과를 초래합니다. [149]. SVM은 과적합 문제를 간단히 선택하여 관리할 수 있다는 이점을 제공합니다. 적절한 데이터 분리 마진(즉, 지원 벡터)[150].

4.2.2 인공신경망

인공 신경망(ANN)은 인간의 뇌를 시뮬레이션하기 위해 개발된 기계 학습 기술의 한 형태입니다[151]. 즉, 인간 신경계의 뉴런이 이전 데이터로부터 학습할 수 있는 것처럼 ANN도 데이터로부터 학습하고 분류 또는 예측의 형태로 응답할 수 있습니다. ANN은 인공 뉴런 또는 노드라고 하는 간단한 처리 단위와 이들의 연결로 구성됩니다. 두 단위 간의 연결의 가중치는 한 단위가 다른 단위에 미치는 영향을 평가하는 데 사용됩니다. 일부 단위는 입력 노드 역할을 하고, 일부는 숨겨진 노드 역할을 하며, 나머지는 출력 노드 역할을 하여 합계와 임계값을 지정합니다[150].

신경망에는 그림 11에서와 같이 입력 층, 은닉 층, 출력 층[152]의 세 가지 필수 층이 있습니다. ANN의 입력 층은 숫자, 텍스트, 이미지 픽셀, 오디오 파일 등의 형태로 데이터를 수신하는 초기 층입니다. 은닉 층은 ANN 모델의 중간에 있습니다. 퍼셉트론과 같이 단일 은닉 층을 가질 수도 있고 여러 개의 은닉 층을 가질 수도 있습니다. 이러한 은닉 층은 입력 데이터를 사용하여 다양한 유형의 수학적 계산을 실행하고 패턴을 인식합니다. 중간 층의 엄격한 계산으로 얻은 결과는 출력 층에 있습니다.

신경망의 성능은 여러 매개변수와 하이퍼 매개변수의 영향을 받습니다. ANN의 출력은 대부분 이러한 매개변수의 영향을 받습니다. 가중치, 편향, 배치 크기, 학습률 및 기타 매개변수가 그 중 일부입니다. 인공 뉴런은 생물학적 뉴런의 기능을 모방하도록 설계된 인공 신경망(ANN)의 구성 요소입니다. 네트워크의 각 인공 뉴런(노드)에는 가중치 세트가 첨부되어 있습니다.

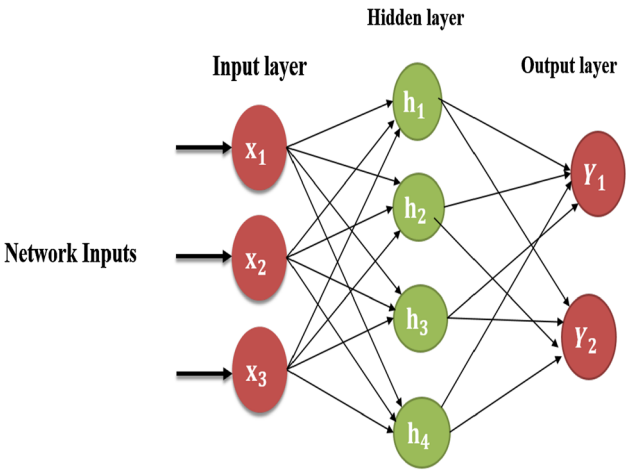

그림 11 ANN의 기본 구조

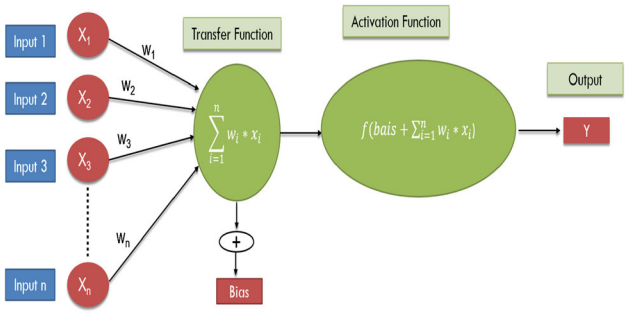

그림 12 인공 뉴런의 모델

그림 12에 표시된 대로 입력의 가중 합과 편향은 전달 함수를 사용하여 계산됩니다. 활성화 함수는 전달 함수가 합을 계산한 후 결과를 받습니다. 활성화 함수는 수신된 출력을 기반으로 노드에서 적절한 결과를 발생시킵니다. 활성화 함수는 출력이 지정된 임계값을 충족하는지 확인하고 0 또는 1을 출력합니다. 인공 신경망에서는 시그모이드, ReLU, Softmax, Tanh 및 기타 일반적인 활성화 함수가 활용됩니다[153]. 노드에서 발생시킨 값에 따라 최종 출력을 얻습니다. 그런 다음 오류 함수의 도움으로 예측 출력과 실제 출력 간의 차이를 계산하고 역전파를 사용하여 신경망의 가중치를 수정합니다.

신경망에는 다양한 유형과 아키텍처가 있으며 각각 학습 방법에 기본적인 차이가 있습니다. 문헌[151, 152]에 잘 설명되어 있습니다. 이러한 아키텍처 중에는 다층 퍼셉트론 신경망(MLPNN)과 익스트림 러닝 머신(ELM)이 있습니다.

4.2.3 의사결정 트리

결정 트리(DT)는 회귀 및 분류 문제 모두에 사용되는 일반적인 머신 러닝 방법입니다. 이는 데이터 집합을 데이터 분리를 최대화하는 기준에 따라 여러 하위 집합으로 나누고 이 프로세스를 재귀적으로 반복하여 트리를 생성하는 것을 기반으로 합니다[154, 155]. 가장 일반적으로 사용되는 기준은 정보 이득으로, 각 분할로 인한 엔트로피 감소가 최대화됨을 의미합니다.

결정 트리의 각 리프 노드에는 클래스 레이블이 지정됩니다. 루트 노드 및 기타 내부 노드와 같은 비터미널 노드는 고유한 특성을 가진 레코드를 구별하는 데 도움이 되는 속성 테스트 조건을 전달합니다[156]. 각 결정 트리 노드는 규칙으로 정의할 수 있습니다. 결정 트리의 상위 노드는 전체 샘플 정확도에 더 큰 영향을 미칩니다[157].

J. Ross Quinlan은 1970년대 후반과 1980년대 초반에 결정 트리 생성 알고리즘인 ID3(Iterative Dichotomizer 3)를 만들었습니다. 그는 C4.5 방법을 개선된 방법으로 제시했습니다. ID3의 몇 년 후 버전. [158]에 따르면, C4.5는 새로운 지도 분류 알고리즘의 기반을 제공합니다. J48 알고리즘은 C4.5 분류 방법의 Java 기반 버전으로, 처음 C로 빌드된 후 알고리즘을 다시 코딩해야 할 필요성의 결과로 등장했습니다. [156] 알고리즘은 최적의 솔루션을 생성하든 그렇지 않든 항상 최상의 로컬 평가 단계를 선택하고 루트와 리프 사이에 서브 트리를 생성하여 문제를 하위 문제로 분해합니다. Salvatore Ruggieri는 2002년에 C4.5와 동일한 결정 트리를 계산하지만 성능이 최대 5배 향상된 분류 기술인 EC4.5를 만들었습니다. [159].

의사결정 트리는 블랙박스 모델이 아니며 규칙으로 쉽게 표현할 수 있다는 점에서 다른 머신 러닝 방법보다 이점이 있습니다. 이러한 이점은 많은 응용 분야에서 더 큰 영향을 미치므로 이러한 모델은 널리 사용됩니다.

4.2.4 랜덤 포레스트

랜덤 포레스트(RF)[160]는 훈련 중에 분류 및 회귀를 수행하기 위해 의사결정 트리의 포레스트를 사용하는 정교한 앙상블 접근 방식입니다.배깅 알고리즘 개념을 기반으로 합니다.의사결정 트리를 생성하는 동안 기능의 하위 집합만 사용하므로 대량의 데이터를 처리할 수 있습니다.다른 분류기에 비해 훈련하는 데 걸리는 시간이 훨씬 짧습니다[161].랜덤 포레스트는 이러한 모든 특성으로 인해 인기 있는 분류 기술입니다.모든 의사결정 트리의 투표는 RF의 최종 출력을 결정합니다[162].단계별 RF 작업 모델은 아래와 같습니다.

– 훈련 세트는 무작위로 선택되고 샘플 세트와 동일한 크기입니다. – 각 훈련 세트는 결정 트리를 구축하는 데 사용됩니다. – 동일한 가능성을 가진 모든 속성에서 무작위로 속성 그룹을 추출한 후 이 하위 세트에서 노드를 분할할 최상의 속성을 선택합니다. – 각 결정 트리에서 예측을 얻습니다. – 각 예측 결과에 대해 투표를 얻습니다. – 최대 투표 결과를 선택하여 최종 결정을 내립니다.

4.2.5 k-최근접 이웃

k-최근접 이웃(K-NN)은 회귀 및 분류 문제에 사용되는 지도 학습 및 통계 기반 머신 러닝 알고리즘 중 하나입니다[163]. K-NN 알고리즘은 시간이 지남에 따라 크게 개선되었으며 현재 텍스트 인식[164], 감정 인식[165] 및 얼굴 인식[166]과 같은 다양한 분야에서 널리 사용됩니다.

훈련 세트와 테스트 세트 사이의 유사성 측정(예: 거리 함수)을 기반으로 한 K-NN의 아이디어. 객체 x의 클래스를 식별하라는 요청을 받았을 때 객체 x와 가장 유사한 훈련 예제를 찾습니다. 그런 다음 이 예제의 클래스로 x에 레이블을 지정합니다. 알고리즘의 정확도는 최근접 이웃(k)의 수가 증가함에 따라 향상될 수 있습니다

· K-NN 접근 방식은 학습 샘플 세트를 선택하는 것으로 시작합니다. 이웃 수(k)를 선택합니다. K-NN은 테스트 샘플과 학습 샘플 간의 유클리드 거리를 사용하여 Eq.16에 표시된 대로 각 새 테스트 인스턴스에 대해 학습 세트에서 가장 가까운 K-샘플을 찾습니다. 선택한 K 이웃 중에서 각 클래스에 있는 학습 샘플의 수를 세어 보세요. 테스트 인스턴스의 대상 클래스는 K-학습 샘플의 가장 일반적인 클래스 값에 의해 결정됩니다[163]. K-NN의 비용은 과도한 계산 복잡도입니다. 데이터 세트의 데이터 양은 계산 복잡도를 결정합니다. 결과적으로 K-NN은 샘플 수가 적은 데이터 세트에 가장 적합합니다.

$$D(A,B) = \sqrt{\left(\sum_{i=1}^{n} |a_i, b_i|^2\right)} \tag{16}$$

4.2.6 나이브 베이즈

나이브 베이즈(NB) 분류기는 높은 독립성 가정을 가진 베이즈 정리에 기반한 확률적 분류 알고리즘입니다[167, 168]. NB 분류기는 클래스에서 한 기능의 존재(또는 부재)가 다른 기능의 존재(또는 부재)에 영향을 미치지 않는다고 가정합니다. NB 분류기는 클래스에서 한 기능의 존재(또는 부재)가 다른 기능의 존재(또는 부재)에 영향을 미치지 않는다고 가정합니다. 최대 우도 기법은 나이브 베이즈 모델에서 매개변수를 계산하는 데 활용됩니다[169]. NB 분류기는 확률 모델의 정확한 특성을 기반으로 지도 학습 설정에서 매우 효과적으로 가르칠 수 있으며 분류를 위해 최소한의 교육 데이터만 필요합니다. 이 분류기의 결과 클래스는 사후 확률이 가장 높은 클래스입니다.

4.3 딥러닝 개요

딥 러닝(DL)은 주어진 데이터로부터 학습할 수 있는 머신 러닝과 인공 지능의 하위 집합입니다[170]. 여러 분류 및 회귀 작업과 데이터 세트에서 DL은 상당한 결과를 낼 수 있습니다. 이는 의료, 시각 인식, 텍스트 분석, 사이버 보안 및 기타 다양한 분야에 응용되는 컴퓨팅 분야에서 인기 있는 주제가 되었습니다[171].

DL은 신경망에 여러 개의 숨겨진 계층을 사용하여 다양한 수준의 비선형 연산을 수행합니다. 복잡한 함수는 다양한 변환과 여러 숨겨진 계층을 사용하여 분류 작업에서 출력 클래스를 식별하도록 훈련될 수 있습니다. 심리생리학에서 감정 연구의 오랜 역사에 비하면 비교적 새로운 사실임에도 불구하고 자동화된 감정 인식을 위한 딥 러닝(DL) 기술 사용에 대한 여러 연구가 최근에 발표되었습니다. Scopus 데이터베이스의 데이터를 기반으로, 그림 13a는 2014년부터 2021년까지의 DL 및 EEG 감정 인식 및 분류 연구 통계를 보여줍니다. 그림 13b는 EEG 감정 인식 연구 분야의 DL 분포를 보여줍니다.

분류 성능을 개선하고 컴퓨팅 시간을 절약하기 위해 피처 추출 및 피처 선택은 더 작은 피처 세트를 찾습니다. 심층적 피처 추출과 얕은 피처 추출은 두 가지 유형의 피처 추출입니다. 시간 영역, 주파수 영역 및 시간-주파수 영역과 같이 다양한 분석 영역에서 수작업으로 만들어진 피처를 얕은 피처라고 합니다. 섹션 3.4에서 설명한 대로 여러 피처 선택 또는 축소 접근 방식을 사용하여 고차원 피처를 최소화합니다. 불행히도 얕은 피처는 주로 휴리스틱에 의존하고 엄청난 양의 레이블이 지정된 데이터가 필요하며 이는 실제 응용 프로그램의 맥락에서 얻기 어려울 수 있습니다. 수동 피처 추출 및 선택은 일반적으로 시간이 많이 걸리고 지루하지만 머신 러닝 모델의 성능에 상당한 영향을 미칩니다. 수작업으로 만든 얕은 피처는 종종 영역에 따라 다르므로 다른 문제에서 재사용하기 어렵습니다.

고전적인 피처 엔지니어링 및 머신 러닝 기술은 여러 변수가 있는 시계열 데이터에서 복잡하고 비선형적인 패턴을 추출하는 데 어려움을 겪을 수 있습니다. 또한 큰 피처 세트에서 가장 중요한 피처를 선택하는 것이 중요하며 차원 축소 접근 방식을 사용해야 합니다. 또한 피처 추출 및 선택은 계산하는 데 오랜 시간이 걸립니다. 예를 들어 피처 선택을 계산하는 비용은 피처 차원이 커짐에 따라 기하급수적으로 증가할 수 있습니다. 일반적으로 검색 알고리즘은 특정 ML 모델에 가장 적합한 피처 세트를 찾지 못할 수 있습니다.

많은 연구자들이 시계열 데이터에서 유용하고 안정적인 특징을 추출하는 과제를 해결하기 위해 DL 기술에 집중해 왔습니다. DL은 ML 알고리즘을 위해 수작업으로 특징을 추출하는 것을 더 쉽게 해줍니다. 오히려, 특징의 계층적 표현을 자율적으로 학습하는 기능이 있습니다. 기존의 머신 러닝 파이프라인에서 이는 특징 공간 재구성 및 데이터 전처리에 대한 요구 사항을 제거합니다. 인공 신경망(ANN)은 딥 러닝의 핵심이며, 이름의 '딥'은 신경망의 계층 수를 나타냅니다. 입력과 출력을 포함하는 3개 이상의 계층을 가진 신경망을 딥 러닝 알고리즘이라고 합니다. DL의 경력은 1980년대에 시작되었습니다. 아마도 최초의 인공 신경망은

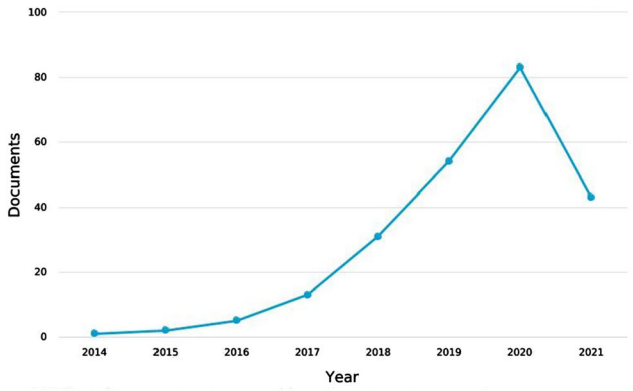

(a) Histogram of DL for EEG emotion recognition publications.

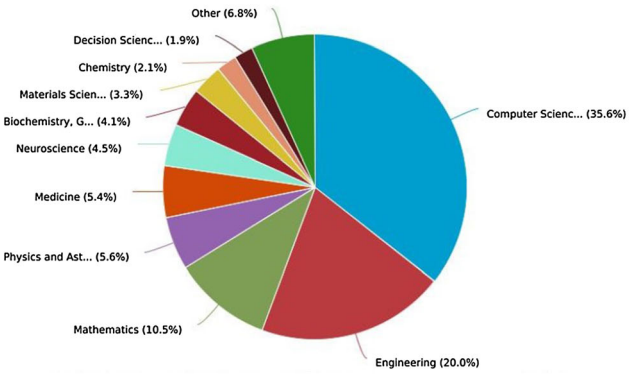

(b) Distribution of DL for EEG emotion recognition research area.

그림 13 최근 10년(2014~2021년) 동안 Scopus 데이터베이스를 기반으로 수행된 EEG 감정 인식 연구를 위한 딥러닝 방법

neocognitron[172]은 "깊은" 속성을 가지고 신경생리학적 통찰력을 고려합니다. Hinton과 Salakhutdinov[173]는 2006년에 기능 추출에 상당한 기여를 했으며, 이는 이후 몇 년 동안 추적되었습니다[174 – 177]. 다양한 연구[178 – 180]에 따르면, 다층 NN은 반복적 또는 비반복적 방법론을 활용하여 기능을 표현하고 학습하는 데 사용할 수 있습니다.

딥 신경망은 DL 기술에서 고수준 데이터 표현을 적용하여 관련 피처를 추출하는 데 활용됩니다. 원시 데이터를 직접 처리하고 피처 추출 및 선택을 자동화하는 기능은 DL 접근 방식의 매력적인 측면입니다. 네트워크에는 시계열 샘플이 공급되고 각 비선형 변환 후에 이전 계층의 입력에 대한 숨겨진 표현이 생성되어 계층적 데이터 표현 구조가 생성됩니다. 다시 말해, 딥 네트워크 패러다임에서 각 계층은 이전 계층의 출력을 가져와 비선형 매핑을 사용하여 이를 새로운 피처 세트로 변환합니다.

최근, 오토인코더, 딥 빌리프 네트워크(DBN), 합성곱 신경망 및 순환 신경망과 같은 딥 러닝 알고리즘은 음성 인식, 컴퓨터 비전, 객체 인식, 자연어 처리 및 기계 번역과 같은 다양한 응용 분야에 큰 영향을 미쳤습니다. 다양한 딥 아키텍처 모델이 제안되어 EEG 신호에 적용되었으며 다른 기존 방법과 비교하여 비슷한 결과를 얻었습니다[181 – 184]. 최근 몇 년 동안 DL은 고수준 데이터 추상화를 제공하는 능력으로 인해 재구성 가능한 감정 인식 아키텍처를 구성하는 데 사용되었습니다.

최근 몇 년 동안 인간의 감정 인식을 위한 EEG 신호 분류를 관리하기 위해 여러 DL 모델이 구현되었습니다. 이러한 방법 중 특수한 유형으로 장단기 기억 네트워크(LSTM)를 갖춘 순환 신경망(RNN)과 분류 방법으로 널리 사용되는 합성곱 신경망(CNN)이 있습니다. 다음 섹션에서 이에 대해 간략히 설명하겠습니다.

4.3.1 순환 신경망

순환 신경망(RNN)은 시계열 데이터(센서), 사운드 또는 자연어와 같은 가변 길이 순차 데이터를 처리하기 위한 딥 러닝 방법입니다. 순환적으로 연결된 피드포워드 신경망으로 구성되어 있습니다. 이는 다른 시점에서 데이터 간의 시간적 상관 관계를 활용하여 입력의 전체 기록을 네트워크에 매핑하고 각 출력을 예상합니다.

표준 신경망에서 모든 입력(및 출력)은 서로 독립적인 것으로 간주됩니다. RNN은 순환 연결이 있고 시간적 순차적 데이터를 학습할 수 있는 신경망의 일종입니다. RNN 네트워크는 각 은닉 계층에 내부 피드백 루프가 있기 때문에 동적인 시간적 패턴을 포착하고 정보를 저장할 수 있습니다. 여러 노드가 RNN의 은닉 계층을 구성하며, 현재 사용 가능한 입력과 이전 은닉 상태를 기반으로 출력을 생성합니다.

시간을 통한 역전파(BPTT) 알고리즘[185]은 RNN을 훈련하는 데 활용될 수 있습니다. 그러나 RNN은 폭발하는 그래디언트 및 사라지는 문제 때문에 훈련하기 어렵고, 이로 인해 네트워크가 확장된 시간 간격에 걸쳐 그래디언트를 역전파하기 어려울 수 있습니다[186, 187]. 이는 시퀀스 데이터에 필수적인 컨텍스트의 양을 제한합니다. 결과적으로 LSTM(장단기 메모리) 및 GRU(게이트 순환 단위)[187]가 대안으로 인기를 얻었습니다.

4.3.1.1 장단기 메모리 네트워크 장단기 메모리 네트워크(LSTM)는 고유한 아키텍처를 갖춘 일종의 순환 신경망(RNN)입니다. Hochreiter와 Schmidhuber는 1997년에 RNN의 장기 종속성 문제를 해결하기 위해 이를 도입했습니다[188]. 기존 RNN은 시간에 따른 역전파(BPTT)[185]로 학습하기 때문에 긴 시퀀스를 학습하는 것이 어려울 수 있으며, 이로 인해 사라지거나 폭발하는 그래디언트 문제가 발생합니다[186]. 이 문제를 해결하기 위해 RNN 셀을 LSTM 셀과 같은 게이트 셀로 대체합니다.

LSTM 셀에는 메모리 블록과 LSTM 연결을 통해 정보를 전달할 수 있는 게이트가 있습니다. 이러한 게이트로 들어가고 나올 수 있는 연결이 여러 개 있습니다. 메모리 블록에서 네트워크의 시간 상태는 자체 연결이 있는 메모리 셀에 저장되고 정보 흐름은 게이트라고 하는 특정 곱셈 단위로 제어됩니다[188]. 원래 구성에서 각 메모리 블록에는 입력 게이트, 망각 게이트, 출력 게이트의 세 개의 게이트가 있습니다. 첫 번째 게이트는 망각 게이트로, 시그모이드 계층을 사용하여 셀 상태에서 어떤 정보를 버려야 할지 선택합니다. 입력 게이트는 두 번째 게이트로, 어떤 값을 업데이트하도록 설정했는지 확인하기 위한 시그모이드 계층과 새로 업데이트된 값의 벡터를 만들기 위한 tanh 계층이 포함됩니다. 마지막으로 현재 상태의 출력은 시그모이드 계층과 업데이트된 셀 상태를 사용하여 계산됩니다. 시그모이드 계층은 셀 상태의 어떤 측면이 최종인지 결정합니다.

4.3.2 합성곱 신경망

합성곱 신경망(CNN)은 동물의 시각 피질 구조를 기반으로 한 일종의 딥 피드포워드 인공 신경망으로, 이미지 분석에 가장 많이 사용됩니다. 입력이 이미지라는 가정은 CNN 아키텍처에서 명확하여 특정 속성을 아키텍처에 인코딩할 수 있습니다. 결과적으로 포워드 함수를 구성하는 것이 더 효율적이고 네트워크의 매개변수 수가 크게 감소합니다. 뉴런이 이전 계층의 모든 뉴런에 연결된 기존의 완전 연결 네트워크와 달리 CNN의 뉴런은 로컬 수용 필드라고 알려진 계층의 특수한 부분에만 연결됩니다. CNN은 설계에 세 가지 유형의 계층이 있습니다. (1) 합성곱, (2) 풀링, (3) 완전 연결 계층[189]. 합성곱 및 풀링 계층은 기능 추출을 위한 반면 완전 연결 계층은 분류와 같이 이러한 기능을 최종 출력으로 전송합니다.

합성곱 계층은 CNN 설계의 중요한 부분으로, 이는 특징을 추출하기 때문이며, 이는 종종 합성곱 프로세스 및 활성화 함수와 같은 선형 및 비선형 프로세스의 혼합을 포함합니다. 합성곱은 특징을 추출하는 데 사용되는 선형 프로세스의 한 형태이며 여러 개의 특징 맵으로 구성됩니다. 전자의 고유한 지점의 로컬 특성은 동일한 특징 맵의 각 뉴런을 사용하여 추출됩니다. 비선형 활성화 함수는 합성곱과 같은 선형 연산의 출력에 적용됩니다. ReLU(rectified linear unit)는 오늘날 가장 널리 사용되는 비선형 활성화 함수로, 선형 연산을 비선형으로 변환하는 데 사용됩니다. 풀링 계층은 특징 맵의 차원을 최소화하고 특징 추출 견고성을 개선하는 데 사용됩니다. 합성곱 계층 출력 값은 또한 풀링 계층의 슬라이딩 필터를 사용하여 선택됩니다. 평균 및 최대 풀링 계층은 풀링 계층의 두 가지 형태입니다. 완전히 연결된 계층은 생성된 모든 특징을 받습니다. 이 계층의 출력은 모든 클래스에 대한 확률 분포입니다. 완전히 연결된 계층은 분류의 최종 결과입니다. 이전 계층의 모든 뉴런을 단일 계층으로 결합합니다.

EEG 기반 BCI를 활용한 5가지 인간 감정 인식 기술

최근 몇 년 동안 EEG 데이터 수집을 위한 BCI 장치를 사용한 감정 인식에 대한 여러 연구 논문이 발표되었습니다. 이러한 논문은 여러 가지 기계 학습 및 심층 학습 기술을 사용합니다. Scopus 데이터베이스에 따르면 그림 14는 2015년부터 2021년까지 가장 널리 사용된 분류기인 ANN, SVM, RF, K-NN, NB 및 심층 학습을 사용한 논문의 수를 보여줍니다. 이 섹션에서는 다음 섹션에 표시된 것처럼 EEG 감정 인식을 위한 널리 퍼진 기계 학습 및 심층 학습 기술 중 일부를 논의하고 검토합니다.

5.1 EEG 감정 인식을 위한 머신 러닝 방법

EEG 데이터에서 다양한 감정 상태를 분류하기 위해 다양한 기계 학습 방법이 사용됩니다.

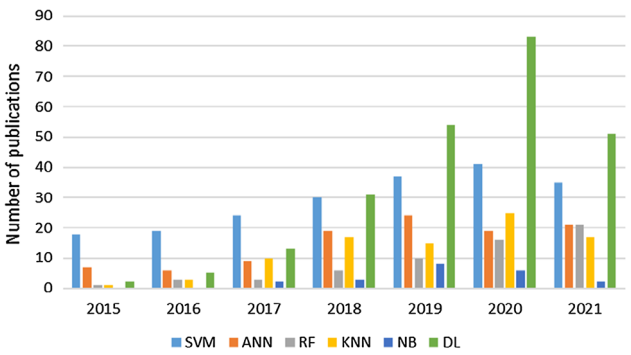

그림 14. Scopus 데이터베이스를 기반으로 한 EEG 감정 인식을 위한 가장 일반적으로 사용되는 머신러닝 및 딥러닝 방법에 대한 2015년부터 2021년까지의 출판물 수

표 5 요약 o f EEG 감정 분류 논문은 전통적인 기계 학습을 사용합니다. 중2015년~2021년의 에토스

References	Dataset used	Classification methods	Emotions	Acc (%)
[63]	Own dataset	SVM	Disgust	Avg.90.2
[56]	DEAP	C4.5	2class/Arousal 2class/Valence	Arousal: 69.09 Valence: 67.89
[64]	GAMEEMO	MLPNN	HAPV, HANV, LAPV and LANV Positive and negative	4 classes/avg. 73.2 2 classes/avg. 81.36
[57]	DEAP	MLPNN	Positive and negative	77.14
[67]	DEAP and SEED	GELM	DEAP: HAHV,HALV, LAHV and LALV SEAD: Positive, neutral and negative	DEAP: 69.67 SEED: 91.07
[58]	DEAP	ANN	2class/Arousal 2class/Valence	Arousal: 82.11 Valance: 82.03
[68]	DEAP and SEED	RF, K-NN, DT	Positive, neutral (calm) and negative	DEAP: 62.63 SEED: 74.85
[59]	DEAP	LSSVM (Linear)	2class/Arousal, 2class/Valence	Arousal:64.84 Valence: 61.17
[55]	DEAP	SVM ((RBF))	2class/Arousal, 2class/Valence	Arousal: 73.06 Valence: 73.14
[69]	DEAP	SVM and RVM	2class/Arousal, 2class/Valence, 2class/Dominance and 2class/Liking.	Arousal: 68 Valence: 65 Dominance: 63 Liking: 67
[70]	DEAP	SVM (RBF)	2class/Arousal, 2class/Valence	Arousal: 67.7 Valence: 69.6
[71]	Own dataset	LIBSVM	2class/Arousal, 2class/Valence	Arousal: 74.88 Valence: 82.63
[72]	DEAP and MAHNOB-HCI	LSSVM (RBF)	2class/Arousal, 2class/Valence	DEAP: Arousal: 65 Valence: 68 MAHNOB-HCI: Arousal: 67 Valence: 70
[65]	DEAP	K-NN	2class/Arousal, 2class/Valence	Arousal: Avg. 92.9 Valence: Avg. 92.8
[73]	DEAP	LDA	Positive, negative, angry and harmony	82
[74]	DEAP	MLPNN	HVHA, LVLA, HVLA and LVHA	93.8
[75]	Own dataset	SVM	Positive, neutral and negative	85.9
[76]	SEED	RFE, SVM	Positive, neutral and negative	93
[77]	DEAP	RF	Happy, sad, angry and relaxed	75.60
[191]	DEAP	NB	Valence, arousal and dominance	78.06

최소 제곱 지원 벡터 머신(LSSVM), 그래프 정규화 극단 학습 머신(GELM), 관련성 벡터 머신(RVM)), 선형 판별 분석(LDA), 회전 포레스트 앙상블(RFE)

벡터 머신(SVM), 랜덤 포레스트(RF), k-최근접 이웃(K-NN), 익스트림 러닝 머신(ELM), 인공 신경망(ANN) 및 나이브 베이즈(NB).

얕은 분류 기술은 모두 신호의 내부 시간적 동적 정보를 고려하지 않고 신호의 특징만을 기준으로 EEG 신호를 분류합니다[190].

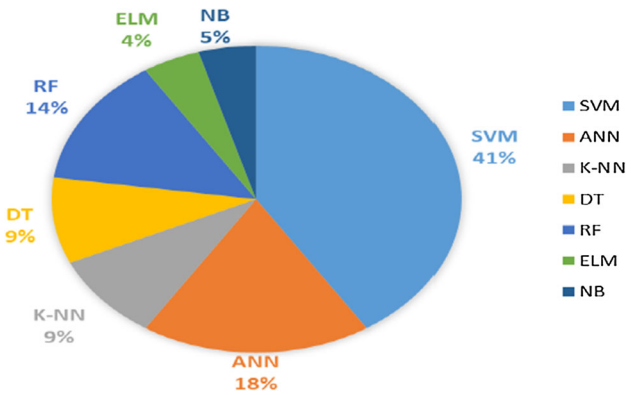

그림 15. 이 리뷰에서 다루는 EEG 감정 인식에 사용되는 다양한 머신 러닝 방법

표 5는 머신 러닝 기술을 사용하여 2015년부터 2021년까지 EEG에서 감정 인식에 대한 연구를 요약한 것입니다. 그림 15는 이 리뷰에서 다루는 EEG 감정 인식에 사용된 여러 머신 러닝 방법의 사용 백분율 차트를 보여줍니다.

표 5에 따르면, 기존 머신 러닝 방법의 분류 정확도는 61.17~93%입니다. 그림 15에서 볼 수 있듯이 SVM과 그 파생물이 가장 일반적으로 사용되어 41%를 차지하며 관련 커널 함수는 가우시안, 선형, 방사형 기저 함수(RBF) 등입니다. 인공 신경망(ANN)과 그 아키텍처인 MLP NN이 18% 사용률로 두 번째로 인기가 높습니다. 연구자의 14%가 RF를 선택합니다. K-NN의 사용은 DT와 유사하여 각각 9%를 차지합니다. 연구자의 5%만이 NB를 선택합니다. ELM은 약 4%로 가장 덜 일반적으로 사용됩니다. 기존 머신 러닝 기술을 나타내는 SVM은 다양한 커널 함수를 사용하여 고차원 공간에서 클래스를 분리할 수 있다는 장점이 있으며 대부분의 연구자가 오랫동안 선택해 왔습니다. 그 결과 이 리뷰에서 알고리즘 사용 빈도 측면에서 1위를 차지했습니다.

5.2 EEG 감정 인식을 위한 딥러닝 방법

최근 몇 년 동안 많은 연구자들이 딥 러닝 기술을 채택했습니다. 표현 학습과 높은 분류 정확도에서 순환 신경망(RNN), 합성곱 신경망(CNN), 딥 신경망(DNN), 딥 신념 네트워크(DBN) 및 장단기 메모리(LSTM)의 장점으로 인해 더 복잡한 상황을 분류하는 데 사용할 수 있습니다. 결과적으로 점점 더 많은 연구자들이 딥 러닝을 EEG 감정 감지를 위한 중요한 연구 방법으로 간주하고 있습니다. 표 6은 딥 러닝 방법을 사용하여 이 분야에서 수행된 연구를 요약한 것입니다.

2015년부터 2021년까지. 그림 16은 이 리뷰에서 다루는 EEG 감정 인식에 사용된 다양한 딥러닝 기술의 사용 비율을 나타낸 차트입니다.

표 6에 따르면, 딥 러닝 알고리즘의 분류 정확도는 61.25%에서 97.56% 사이에서 다양합니다. 기존의 머신 러닝 방법은 딥 러닝 방법만큼 좋은 분류 효과가 없다는 것을 알 수 있습니다. EEG 신호의 특성을 결정하기 위해 기존의 머신 러닝 기술은 많은 사전 지식이 필요합니다. 그러나 다양한 사람들은 복잡한 인지 과정에서 상당한 차이를 가지고 있어 효과적인 특징을 찾기 어렵습니다. 이 모든 것이 EEG 신호 분류 정확도를 개선하는 것을 극도로 어렵게 만듭니다. 기존의 머신 러닝 알고리즘과 달리 딥 러닝은 광범위한 사전 지식이나 수동적인 특징 추출이 필요하지 않습니다. 복잡한 데이터에서 레벨별로 특징을 추출할 수 있습니다. 그림 16에서 볼 수 있듯이 LSTM과 그 파생물이 가장 일반적으로 사용되어 전체의 50%를 차지합니다. CNN과 그 파생물은 두 번째로 인기가 있어 연구의 36%를 차지합니다. DBN과 DNN은 각각 7%의 비중을 차지하며 가장 인기가 없습니다.

6. 과제 및 미래 연구 방향

이 리뷰 연구에서 보여 주듯이, 우리는 BCI 장치를 사용하여 EEG 신호를 기록하고 이를 현대 ML 및 DL 알고리즘을 사용하여 분석하여 감정 감지 기술을 실제 세계에 적용할 수 있습니다. 그러나 해결해야 할 미해결 문제가 있습니다. 평균적으로 EEG 신호를 활용한 감정 감지에 대한 기존 접근 방식은 80% 이상의 분류 정확도를 생성했으며, 이는 실용적인 응용 분야에 적합한 것으로 보입니다. 그러나 인식 정확도는 각 응용 분야에 고유하며 연구에 사용된 데이터 세트에 크게 의존합니다. 다음은 이 리뷰에서 발견된 감정 인식 분야의 몇 가지 미해결 문제와 미래 연구 방향입니다.

1. 기존 연구는 주로 주관적 종속 감정 인식 문제에 초점을 맞추고 있으며, 이는 각 참여자에게 개인화된 분류기를 필요로 합니다. 주체에 독립적(또는 일반적)이고 개인 집합에 적합한 감정 인식 모델은 실제 상황에서 매우 유용할 것입니다. 그러나 개인 간에 일관된 감정 감지 정확도를 달성하려면 주체에 독립적인 분류기 모델을 전이 학습 기술과 통합해야 합니다.

2. 알려진 EEG 데이터 세트의 대부분은 실험실 환경에서 시각적 유도 도구를 사용하여 수집되었습니다. 이전 연구에서 피험자의 감정 상태

표 6 합계 20년 동안 DL 방법을 사용한 EEG 감정 분류 논문의 메리 15 – 2021

References	Dataset used	Classification methods	Emotions	Acc (%)
[78]	Own dataset	BiLSTM	Positive, neutral and negative	72.83
[192]	Own dataset	DL withRBM	Happy, calm, sad, and scared	68.4
[80]	DEAP	DNN	2class/Arousal, 2class/Valence	Arousal: 61.25 Valance: 62.50
[81]	DEAP and SEED	LSTM	HAHV,HALV, LAHV and LALV, 2class/Arousal, and 2class/Valence Positive, neutral and negative	DEAP: 4 classes: 82.01 Arousal: 85.21 Valance: 84.16 SEED: 90.81
[82]	SEED	SRU	Positive, neutral and negative	80.02
[193]	Own dataset	LSTM	Happy, fear, anger, sad, Surprise and disgust	87.25
[194]	DEAP and DREAMER	RACNN	2class/Arousal, 2class/Valence	DEAP: Arousal: 97.11 Valence: 96.65 DREAMER: Arousal: 97.01 Valence: 95.55
[83]	DEAP,DREAMER, SEED and AMIGOS.	CNN+SVM	2class/Arousal, 2class/Valence Positive and negative	DEAP: Arousal:77.7 andValence: 76.6 DREAMER: Arousal: 90.4 andValence: 88.2 AMIGOS: Arousal :90.5 andValence: 78.4 SEED: 88.5
[84]	Own dataset, DEAP and SEED	LSTM	Disgust, sadness, surprise and anger Positive, negative, and neutral	DEAP: 91.38 SEED: 89.34 Own dataset 4 class: 94.12 3 class: 92.66
[195]	DEAP	BiDCNN	2 class/Arousal, 2 class/Valence	Subject-dependent Arousal:94.72 Valence: 94.38 Subject-independent Arousal: 63.94 Valence: 68.14
[196]	DEAP	LSTM	2 class/Arousal, 2 class/Valence, 2 class/Liking	Arousal: 85.65 Liking: 87.99 Valence: 85.45
[66]	DEAP	Merged LSTM	2class/Arousal, 2class/Valence, 2 class/Liking 2 class/Dominance	Arousal 83.85 Valence 84.89 Liking 80.72 Dominance 84.37
[79]	Own dataset	BiLSTM	Neutral, sad, fear, and Happy	84.21
[85]	SEED and	DGCNN	Positive, neutral and	SEED:

표 6 (계속)

References	Dataset used	Classification methods	Emotions	Acc (%)
	DREAMER		negative	90.40
			2class/Arousal,	DREAMER:
			2class/Valence,	Arousal 84.54 Valence 86.23
			2 class/Dominance	Dominance 85.02
[86]	SEED	DECNN	Positive and negative	97.56
[197]	DEAP	3D-CNN	2class/Arousal,	Arousal 88.49 Valence 87.44
			2class/Valence	

제한 볼츠만 머신(RBM), 단순 순환 단위(SRU), 지역 비대칭 합성 신경망(RACNN), 양반구 불일치 합성 신경망(BiDCNN), 양방향 장단기 기억 네트워크(BiLSTM), 동적 그래프 합성 신경망(DGCNN), 동적 경험적 합성 신경망(DECNN)

실험이 수행되기 전의 것은 고려되지 않았습니다. 이러한 개별적인 차이로 인해 데이터 세트가 일관되지 않을 수 있습니다.

3. 많은 연구에서는 각 감정 차원의 이진 분류만 고려했습니다.
4. 많은 감정 인식 연구에서 연구자들은 다양한 감정 상태에서 EEG 데이터를 조사했으며 기준(자발적) EEG 데이터는 무시했습니다.
5. 긍정적, 부정적 영향을 동시에 인지하는 씁쓸한 감정과 같은 혼합된 감정에 대한 EEG 기반 감정 감지는 문헌에서 발견되지 않았습니다. 창의적 성과를 개선하기 위한 연구는 이러한 혼합된 감정과 연결되어 있기 때문에 흥미롭습니다[198].

위의 사항들 외에도 다음 사항들은 향후 작업에서 고려될 것입니다.

1. 전통적으로 실제 감정 클래스는 미리 정해진 주관적 평가 데이터 임계값을 기반으로 레이블이 지정되었습니다. 불행히도 적절한 임계값을 결정하는 것은 어렵습니다. 새로운 접근 방식은 다음을 고려하는 것입니다.

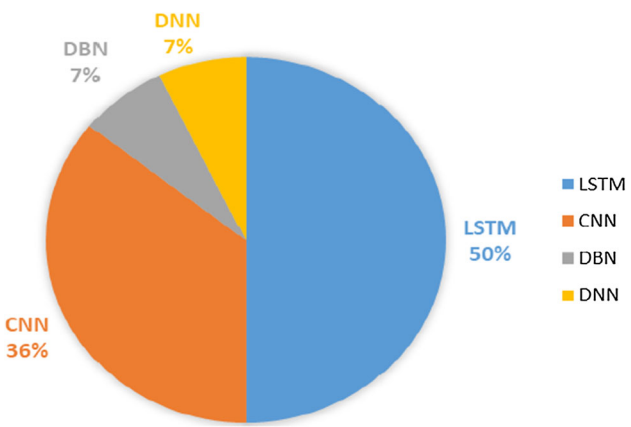

그림 16 이 리뷰에서 다루는 EEG 감정 인식에 사용된 다양한 딥러닝 방법

가치와 각성 차원을 동시에 고려한 후 데이터 클러스터링 방법을 활용하여 감정의 실제 클래스를 찾습니다.

2. 특징 추출 및 선택과 같은 EEG 기반 BCI 시스템 구성 요소는 지속적으로 진화하고 있습니다. 이들은 뇌의 생리학 및 생물학에 대한 철저한 이해를 바탕으로 확립되어야 합니다. 독특한 특징을 만드는 것은 감정 감지 시스템의 결과를 극적으로 개선할 수 있는 잠재력이 있습니다. 예를 들어, 시간 영역 특성은 주파수, 시간-주파수 특징 및 채널 위치와 혼합됩니다.

3. 더 많은 차원의 감정 모델이 개발되어야 합니다. 현재 2차원 감정 모델이 널리 사용되고 있습니다. 다중 클래스 감정 인식은 더 높은 차원의 감정 모델 개발을 필요로 합니다. 예를 들어, 주체의 맥락 정보에 대한 누적된 분석은 3차원 감정 모델에서 '자세' 차원(즉, 각성, 자세, 가치)을 예측할 수 있습니다.

4. 깊고 이전 가능한 ML 기술과 같은 고급 머신 러닝 접근 방식을 개발해야 합니다. 감정은 생물학적 이해와 정신생리학적 사건과 관련된 인지 과정을 반영하며, 이를 만드는 것은 주관적이고 어려운 절차입니다. 결과적으로 고전적인 ML 방법에만 기반한 인식 방법을 제안하는 것은 문제가 있습니다.

5. 실시간으로 시간적 감정 변동을 모니터링하기 위해서는 기존의 시계열 분석 접근방식을 기계 학습 기술과 통합해야 합니다[55, 199 – 203].

6. 감정 인식을 위한 대부분의 엔지니어링 기술은 각성 분류가 가치 구분보다 일반적으로 더 정확하다는 것을 보여줍니다. 이에 대한 근거는 각성 수준의 변화가 자율신경계 활동(예:

피부 전도도와 혈압)은 측정하기 쉬운 반면, 가치 수준의 구별은 교차 연관된 ANS 반응의 요인 분석을 필요로 합니다. 결과적으로, 우리는 감정별 범주화 프레임워크를 만들고 다양한 분석 도메인(예: 시간-주파수, 주파수, 시간, 엔트로피 및 다중 스케일 엔트로피)에서 EEG 데이터로부터 다양한 가치 관련 특성을 추출해야 합니다.

7. 우리는 비디오 게임과 같은 능동적 유발 기술을 사용하는 더 많은 데이터 세트를 만들어야 합니다. 왜냐하면 이러한 데이터 세트는 '실제 생활' 경험을 더 잘 모방하고 감정을 유도하는 데 더 효과적이기 때문입니다.

7 결론

감정 인식은 인간-기계 시스템 및 자동화 기술이 개선됨에 따라 HCI 분야에서 중요성이 커지고 있습니다. 최근 몇 년 동안 EEG 기반 BCI 감정 인식은 감성 컴퓨팅 분야에서 점점 더 많은 주목을 받고 있습니다. 사용 가능성과 사용하기 쉬운 BCI 장치의 생성에 있어 상당한 진전으로 인해 수많은 연구가 수행되었습니다. 이 리뷰를 위해 195개 이상의 출판물을 조사했습니다. 최근 몇 년(2015년~2021년)에 개발된 최첨단 EEG 감정 식별 접근 방식을 다루었습니다. 또한 기존 데이터 세트를 고려하고 EEG 기반 BCI를 활용하는 감정 감지 파이프라인의 주요 구성 요소를 설명했습니다. EEG 신호는 위조하거나 시뮬레이션할 수 없는 신뢰할 수 있는 데이터입니다. EEG는 실시간으로 감정 변화에 반응합니다. 다음 계산 프로세스는 EEG 기반 BCI 감정 인식을 위한 일반적인 방법론을 구성합니다.데이터 수집, 전처리, 기능 추출, 기능 선택 또는 차원 감소, 분류 및 성능 평가. 리뷰에서 우리는 전처리, 기능 추출 및 기능 선택/차원 감소를 위한 여러 기술에 초점을 맞추었습니다. 또한 다양한 머신 러닝 및 딥 러닝 분류 기술과 일반적으로 사용되는 성능 지표를 검토했습니다. 이 리뷰에서 보여지듯이 뇌 신호와 감정 간의 관계를 조사하는 것은 어려운 작업이며, 새로운 방법론과 구현이 끊임없이 개발되고 있습니다. 현재의 많은 과제가 곧 해결될 것으로 예상되어 EEG 기반 감정 식별을 기반으로 하는 광범위한 잠재적 응용 분야의 길을 열 것입니다. 이 리뷰는 연구자, 특히 이 분야를 막 시작한 연구자에게 감정 지향적 EEG 기능의 인식 및 분류에 대한 연구의 현재 상태에 대한 통찰력을 제공하고자 합니다.

자금 지원 과학기술혁신기금청(STDF)이 이집트 지식은행(EKB)과 협력하여 제공하는 오픈 액세스 자금 지원입니다.

선언

이해 상충 저자들은 이해 상충이 없다고 선언했습니다. 비재정적 경쟁 이익.

인간 또는 동물 참가자 이 기사에는 저자 중 어느 누구도 수행한 인간 참가자 또는 동물에 대한 연구가 포함되어 있지 않습니다.

CRediT 저자 진술 Essam H. Houssein은 감독, 방법론, 개념화, 공식 분석, 시각화 및 쓰기(리뷰 및 편집)에 참여했습니다. Asmaa Hammad는 공식 분석, 시각화, 리소스, 데이터 큐레이션 및 쓰기(원본 초안)에 참여했습니다. Abdelmgeid A. Ali는 감독, 방법론 및 쓰기(리뷰 및 편집)에 참여했습니다. 모든 저자가 최종 논문을 읽고 승인했습니다.

참고문헌

1. Mudgal SK, Sharma SK, Chaturvedi J, Sharma A(2020) 신경 과학에서의 뇌-컴퓨터 인터페이스 발전: 응용 및 문제점.Interdiscip Neurosurg 20:100694 2. Wolpaw JR, Birbaumer N, McFarland DJ, Pfurtscheller G, Vaughan TM(2002) 통신 및 제어를 위한 뇌-컴퓨터 인터페이스.Clin Neurophysiol 113(6):767 – 791 3. Abdulkader SN, Atia A, Mostafa M-SM(2015) 뇌-컴퓨터 인터페이싱: 응용 및 과제.Egypt Inf J 16(2):213 – 230 4. Jerry JS, Dean JK, Jonathan RW(2012) 의학에서의 뇌-컴퓨터 인터페이스. Mayo Clinic Proceedings, volume 87. Elsevier, pp 268 – 279 5. Khosla A, Khandnor P, Chand T(2020) EEG 신호를 기반으로 한 다양한 응용 프로그램을 위한 신호 처리 및 분류 방법에 대한 비교 분석. Biocybern Biomed Eng 40(2):649 – 690 6. Jiang W, Mei W(2021) EEG 신호를 사용한 감정적 특징 추출 및 분류 검토. Cognitive Robotics 7. Mamunur R, Norizam S, Anwar PPAM, Rabiu MM, Bifta SB, Sabira K et al(2020) EEG 기반 뇌-컴퓨터 인터페이스의 현재 상태, 과제 및 가능한 해결책: 포괄적 검토. Front Neurorob 14:25 8. Zhang J, Yin Z, Chen P, Nichele S(2020) 다중 모달 데이터와 머신 러닝 기술을 사용한 감정 인식: 튜토리얼 및 리뷰. Inform Fusion 59:103 – 126

9. Calvo RA, D ' Mello S(2010) 영향 감지: 모델, 방법 및 응용 프로그램에 대한 학제간 검토.IEEE Trans Affect Comput 1(1):18 – 37 10. Valery P(1999) 음성의 감정: 인식 및 콜센터에 대한 응용.In: Proceedings of artificial neural networks in engineering, volu me 710, p 22 11. Keith A, McOwan PW(2006) 인간의 얼굴 표정 인식을 위한 실시간 자동화 시스템.IEEE Trans Syst Man Cyberne t B(사이버네틱스) 36(1):96 – 105 12. Yin Z, Zhao M, Wang Y, Ya ng J, Zhang J(2017) 다중 모드 생리 신호와 앙상블 딥 러닝 모델 을 사용한 감정 인식. Comput Methods Programs Biomed 140:93 – 110 13. Torres EP, Torres EA, Hernańdez-A ĺvarez M, Yoo SG(2 020) Eeg 기반 bci 감정 인식: 조사.센서 20(18):5083 14. He Z, Li Z, Yang F, Wang L, Li J, Zhou C, Pan J(2020) 뇌-컴퓨터 인터페이 스 기반 다중 모달 감정 인식의 발전.Brain Sci 10(10):687 15. Xia owei L, Bin H, Tingshao Z, Jingzhi Y, Fang Z(2009) EEG 피드백 접근 방식을 통한 정서적 학습을 향해. In: Proceedings of the first ACM international workshop on Multimedia technologies for distan ce learning, pp 33 – 38 16. Mauss IB, Robinson MD (2009) Measure s of emotion: a review.Cogn Emot 23(2):209 – 237 17. Naji M, Firo ozabadi M, Azadfallah P (2015) Emotion classification during music listening from forehead biosignals.SIViP 9(6):1365 – 1375 18. Paul E (1992) Are the basic emotional?Psychol Rev 19. Russell JA (1980) A circumplex model of affect.J Pers Soc Psychol 39(6):1161 20. C harles D (2015) The expression of the emotional in man and animals . University of Chicago Press, Chicago 21. Silvan T(1962) Affect im agery consciousness: Volume I: The positive affect. Springer publish ing company 22. Ekman P, Oster H(1979) Facial expression of emot ional. Annu Rev Psychol 30(1):527 – 554 23. Gray JA(1985) A who le and its parts: behaviour, the brain, cognition and emotional. Bull British Psychol Soc 24. Mowrer O(1960) Learning theory and behav ior. American Psychological Association, Washington 25. Watson J B, Kimble GA(2017) Behaviorism. Routledge, London 26. Gurney E(1884) What is an emotion? Mind 9(35):421 – 426 27. Panksepp J(1982) Toward a general psychobiological theory of emotionals. Beh av Brain Sci 5(3):407 – 422 28. Weiner B, Sarah G(1984) 감정 발달 에 대한 귀인적 접근법.Emot Cognit Behav 167 – 191 29. Arnold MB(1960) 감정과 성격.American Psy- chological Association, Was hington 30. Johnson-Laird PN, Oatley K(1989) 감정의 언어: 의미 필드 분석.Cogn Emot 3(2):81 – 123 31. Frijda NH et al(1986) 감정 .Cambridge University Press, Cambridge 32. Izard Carroll E(2013) 인간의 감정.Springer, New York 33. McDougall William(2015) 사 회 심리학 입문. Psychology Press, London 34. Whissell CM(1989) 언어의 영향 사전. 에서: 감정의 측정. Elsevier, pp 113 – 131 35. S chlosberg H(1954) 감정의 세 가지 차원. Psychol Rev 61(2):81 36. Yang W, Makita K, Nakao T, Kanayama N, Machizawa MG, Sasao ka T, Sugata A, Kobayashi R, Hiramoto R, Yamawaki S 외 (2018) 감성 청각 자극 데이터베이스: 국제 감성 디지털 사운드(iads-e) 의 확장 버전. 행동 해상도 방법 50(4):1415 – 1429

37. Lang PJ, Bradley MM, Cuthbert BN et al (1997) 국제적 정서 그림 시스템(iaps): 기술 매뉴얼 및 정서 평가.NIMH Center Study Emot Attent 1(39 – 58):3 38. Bradley MM, Lang PJ (1994) 감정 측 정: 자기 평가 마네킹과 의미 차이.J Behav Ther Exp Psychiatry 2 5(1):49 – 59 39. Zhou F, Xingda Q, Jiao J, Helander MG (2014) 생 리적 신호로부터의 감정 예측: 시각적 및 청각적 유발자 간의 비 교 연구.Interact Comput 26(3):285 – 302 40. Yin Z, Zhang J (2018) 신경 생리적 신호와 동적 딥 익스트림 러닝 머신을 기반으로 한 작업 일반 정신 피로 인식. Neurocomputing 283:266 – 281 41. Ber ger H (1929) 인간의 전기 케팔로그램에서 Ü ber. Arch Psychiatr Nervenkr 87(1):527 – 570 42. Teplan M et al (2002) EEG 측정의 기초. Measure Sci Rev 2(2):1 – 11 43. Zhao G, Zhang Y, Ge Y (201 8) 이산 감정의 전두엽 EEG 비대칭 및 중앙선 전력 차이. Front B ehav Neurosci 12:225 44. Zheng W-L, Bao-Liang L (2015) 딥 신경 망을 사용한 EEG 기반 감정 인식을 위한 중요 주파수 대역 및 채널 조사. IEEE Trans Auton Ment Dev 7(3):162 – 175 45. Ekman P, Davidson RJ(1993) 자발적인 미소 짓기가 국소적 뇌 활동을 변 화시킨다.Psychol Sci 4(5):342 – 345 46. Li P, Liu H, Si Y, Li C, Li F, Zhu X, Huang X, Zeng Y, Yao D, Zhang Y et al(2019) 기능적 연 결 네트워크와 국소적 활성화를 결합하여 Eeg 기반 감정 인식.I EEE Trans Biomed Eng 66(10):2869 – 2881 47. Bhatti AM, Majid M, Anwar SM, Khan B(2016) 뇌 신호를 사용하여 오디오 음악에 대한 응답으로 인간의 감정 인식 및 분석.Comput Hum Behav 65: 267 – 275 48. Lee Y-Y, Hsieh S(2014) EEG 기반 기능적 연결 패 턴을 통해 다양한 감정 상태 분류. PLoS ONE 9(4):e95415 49. Pet erson V, Galvań C, Hernańdez H, Spies R(2020) 완전 저가 소비자 등급 뇌-컴퓨터 인터페이스 시스템의 타당성 연구. Heliyon 6(3): e03425 50. Wang Y, Jung T-P(2012) 독립 구성 요소 분석을 사용 하여 뇌-컴퓨터 인터페이스 개선. Towards practical brain-comput er interfaces에서. Springer, pp 67 – 83 51. Ofner P, Mu ̈ller-Putz GR (2015) EEG 및 해당 차별 소스에서 동작 대상 디코딩: 예비 연구. 2015년 제37회 IEEE 의학 및 생물학 공학 학회(EMBC) 연례 국 제 컨퍼런스에서. IEEE, pp 1468 – 1471 52. Alhaddad MJ, Kamel M, Malibary H, Thabit K, Dahlwi F, Hadi A(2012) 공통 평균 참조 를 사용한 P300 스펠러 효율성. 국제 자율 및 지능형 시스템 컨 퍼런스에서. Springer, pp 234 – 241 53. Li X, Fan H, Wang H, Wan g L(2019) EEG 신호 분류를 위한 위상 동기화 정보와 결합된 공 통 공간 패턴. Biomed Signal Process Control 52:248 – 256 54. Koe lstra S, Muhl C, Soleymani M, Lee J-S, Yazdani A, Ebrahimi T, Pun T, Nijholt A, Patras I(2011) Deap: 생리적 신호를 사용하는 감정 분석을 위한 데이터베이스. IEEE Trans Affect Comput 3(1):18 – 3 1 55. Atkinson J, Campos D(2016) EEG 특징 선택과 커널 분류기 를 결합하여 BCI 기반 감정 인식 개선. Expert Syst Appl 47:35 – 4 1 56. Chen J, Bin H, Moore P, Zhang X, Ma X(2015) 온톨로지와 데이터 마이닝 기술을 사용한 뇌파 기반 감정 평가 시스템. Appl Soft Comput 30:663 – 674

57. O¨zerdem MS, Polat H(2017) 채널 선택을 통한 영화 클립의 EEG 특징에 기반한 감정 인식.Brain informatics 4(4):241 – 252 58. Mert A, Akan A(2018) 다변수 동기 압축 변환을 사용한 EEG 신호의 시간-주파수 분포에 기반한 감정 인식.Digit Signal Process 81:106 – 115 59. Kumar N, Khaund K, Hazarika SM(2016) 감정 인식을 위한 EEG의 이중 스펙트럼 분석.Procedia Comput Sci 84:31 – 35 60. Hyvaïinen A, Oja E(2000) 독립 성분 분석: 알고리즘 및 응용 프로그램. Neural Netw 13(4 – 5):411 – 430 61. Papadelis C, Chen Z, Kourtidou-Papadeli C, Bamidis PD, Chouvarda I, Bekiaris E, Maglaveras N(2007) 수면 부족으로 인한 교통 사고를 예방하기 위한 차량 전기 생리학적 기록을 통한 졸음 모니터링. Clin Neurophysiol 118(9):1906 – 1922 62. Asadi Ghanbari A, Nazari Kousarrizi MR, Teshnehlab M, Ali-yari M(2009) ICA를 사용한 뇌-컴퓨터 인터페이스를 위한 진화적 아티팩트 거부 방법. Int J Electr Comput Sci 9(9):48 – 53 63. Iacoviello D, Petracca A, Spezialetti M, Placidi G(2015) 자가 유발 감정에 의해 구동되는 EEG 기반 BCI를 위한 실시간 분류 알고리즘.Comput Methods Programs Biomed 122(3):293 – 303 64. Alakus TB, Gonen M, Turkoglu I(2020) EEG 신호와 다양한 컴퓨터 게임-게임이모를 기반으로 한 감정 인식 시스템을 위한 데이터베이스.Biomed Signal Process Control 60:101951 65. Li M, Hongpei X, Liu X, Shengfu L(2018) k-최근접 이웃 분류를 사용한 다중채널 EEG 신호로부터의 감정 인식. Technol Health Care 26(S1):509 – 519 66. Garg A, Kapoor A, Bedi AK, Sunkaria RK(2019) EEG 신호를 사용한 감정 분류를 위한 병합된 lstm 모델. 2019년 국제 데이터 과학 및 공학 컨퍼런스(ICDSE). IEEE, pp 139 – 143 67. Zheng W-L, Zhu J-Y, Bao-Liang L(2017) EEG에서 감정 인식을 위한 시간 경과에 따른 안정적인 패턴 식별. IEEE Trans Affect Comput 10(3):417 – 429 68. Qing C, Qiao R, Xiangmin X, Cheng Y(2019) EEG 신호를 사용한 해석 가능한 감정 인식. Ieee Access 7:94160 – 94170 69. Gupta R, Falk TH 외(2016) 자동적 정서적 상태 특성화를 위한 관련성 벡터 분류기 결정 융합 및 EEG 그래프 이론적 특징.Neurocomputing 174:875 – 884 70. Arnau-Gonzaĺez P, Arevalillo-Herraéz M, Ramzan N(2017) EEG 신호에서 정서적 상태를 식별하기 위해 고차원 에너지 및 연결성 특징 융합.Neurocomputing 244:81 – 89 71. Chen T, Sihang J, Ren F, Fan M, Yu G(2020) libsvm 분류기를 기반으로 한 EEG 감정 인식 모델. Measurement 164:108047 72. Yin Z, Liu L, Chen J, Zhao B, Wang Y(2020) 개인과 독립적인 감정 인식을 위한 국소적으로 견고한 EEG 특징 선택.Expert Syst Appl 162:113768 73. Chakladar DD, Chakraborty S(2018) 상관관계 기반 하위 집합 선택을 사용한 EEG 기반 감정 분류.Biol Inspired Cognit Architec 24:98 – 106 74. Salankar N, Mishra P, Garg L(2021) 경험적 모드 분해 및 2차 차이 플롯을 사용한 EEG 신호로부터의 감정 인식.Biomed Signal Process Control 65:102389 75. Huang C(2021) EEG 특징을 통한 심리적 감정 인식. 네트워크 모델 분석 Health Inform Bioinform 10(1):1 – 11 76. Subasi A, Tuncer T, Dogan S, Tanko D, Sakoglu U(2021) 조정 가능한 q 웨이블릿 변환 및 회전 포레스트 앙상블 분류기를 사용한 Eeg 기반 감정 인식. Biomed Signal Process Control 68:102648

77. Pane ES, Wibawa AD, Purnomo MH(2019) 튜닝 매개변수를 사용하여 가치 편향 및 앙상블 학습을 결합하여 EEG 감정 인식의 정확도 향상.Cogn Process 20(4):405 – 417 78. Joshi VM, Ghongade RB(2020) 아이디어: EEG 신호를 사용한 감정 분석을 위한 Intellect 데이터베이스.J King Saud Univ-Comput Inform Sci 79. Yang J, Huang X, Hongkai W, Yang X(2020) 양방향 장단기 메모리 네트워크를 기반으로 한 EEG 기반 감정 분류.Procedia Comput Sci 174:491 – 504 80. Pandey P, Seeja KR(2019) VMD 및 딥 러닝을 사용하여 EEG에서 피험자 독립적인 감정 인식. J King Saud Univ-Comput Inform Sci 81. Sharma R, Pachori RB, Sircar P(2020) 고차 통계 및 딥 러닝 알고리즘을 기반으로 한 자동 감정 인식. Biomed Signal Process Control 58:101867 82. Wei C, Chen L, Song Z, Lou X, Li D(2020) 단순 순환 단위 네트워크 및 앙상블 학습을 사용한 Eeg 기반 감정 인식. Biomed Signal Process Control 58:101756 83. Topic A, Russo M(2021) 딥 러닝 네트워크를 통한 Eeg 특징 맵 기반 감정 인식. Int J Eng Sci Technol 84. Sakalle A, Tomar P, Bhardwaj H, Acharya D, Bhardwaj A(2021) 무선 뇌파 구동 시스템을 사용하여 감정을 인식하기 위한 lstm 기반 딥 러닝 네트워크. Expert Syst Appl 173:114516 85. Song T, Zheng W, Song P, Cui Z(2018) 동적 그래프 합성 신경망을 사용한 EEG 감정 인식.IEEE Trans Affect Comput 11(3):532 – 541 86. Liu S, Wang X, Zhao L, Zhao J, Xin Q, Wang S(2020) 동적 경험적 합성 신경망을 기반으로 한 EEG 신호의 피험자 독립적 감정 인식.IEEE/ACM Trans Comput Biol Bioinform 87. Hjorth B(1970) 시간 영역 속성을 기반으로 한 EEG 분석.Electroencephalogr Clin Neurophysiol 29(3):306 – 310 88. Petrantonakis PC, Hadjileontiadis LJ(2009) 고차 교차를 사용한 EEG로부터의 감정 인식. IEEE Trans Inf Technol Biomed 14(2):186 – 197 89. Petrantonakis PC, Hadjileontiadis LJ(2010) 하이브리드 적응 필터링 및 고차 교차 분석을 사용한 뇌 신호에서의 감정 인식.IEEE Trans Affect Comput 1(2):81 – 97 90. Shaw L, Routray A(2016) pca를 사용한 명상 EEG에서 다변량 패턴 분석을 위한 통계적 특징 추출.2016 IEEE EMBS 국제 학생 컨퍼런스(ISC)에 게재.IEEE, pp 1 – 4 91. Liu Y, Sourina O(2014) 프랙탈 차원을 사용한 Eeg 기반 주체 종속 감정 인식 알고리즘.2014 IEEE 시스템, 인간 및 사이버네틱스(SMC) 국제 컨퍼런스에 게재. IEEE, pp 3166 – 3171 92. Yuen CT, San San W, Seong TC, Rizon M(2009) 통계적 특징과 신경망을 이용한 EEG 신호로부터 인간의 감정 분류.Int J Integrat Eng 1(3) 93. Murugappan M, Subbulakshmi M(2013) 고속 푸리에 변환(fft)을 이용한 단시간 뇌파(eeg) 신호를 통한 인간의 감정 인식.In: 2013 IEEE 9th international colloquium on signal processing and its applications.IEEE, pp 289 – 294 94. Yoon HJ, Chung SY(2013) 베이지안 가중 로그 사후 함수와 퍼셉트론 수렴 알고리즘을 이용한 Eeg 기반 감정 추정. Comput Biol Med 43(12):2230 – 2237 95. Shi L-C, Jiao Y-Y, Lu B-L(2013) EEG 기반 각성도 추정을 위한 차등 엔트로피 특징. IEEE Engineering in Medicine and Biology Society(EMBC) 2013년 제35회 국제 연례 컨퍼런스에 게재됨. IEEE, pp 6627 – 6630

96. Subasi A(2007) 웨이블릿 특징 추출과 전문가 모델의 혼합을 사용한 Eeg 신호 분류. Expert Syst Appl 32(4):1084 – 1093 97. Li Y , Yingle F, Gu L, Qinye T(2009) EEG Hilbert-Huang 변환을 기반으로 한 수면 단계 분류. 2009년 4차 IEEE 산업 전자 및 응용 컨퍼런스에서 발췌. IEEE, pp 3676 – 3681 98. Ting W, Guo-Zheng Y, Bang-Hua Y, Hong S(2008) 뇌-컴퓨터 인터페이스를 위한 웨이블릿 패킷 분해를 기반으로 한 Eeg 특징 추출. Measurement 41(6):618 – 625 99. Houssein EH, Hamad A, Hassanien AE, Fahmy AA(2019) 고래 최적화 강화 지원 벡터 머신을 기반으로 한 간질 감지. J Inf Optim Sci 40(3):699 – 723 100. Guido RC(2018) 정보 융합을 위한 엔트로피 기반 수작업 기능 추출에 대한 튜토리얼 리뷰.Inform Fusion 41:161 – 175 101. Vijith VS, Elsa Jacob J, Iype T, K Gopakumar , George Yohannan D(2016) EEG의 비선형 분석을 사용한 간질 발작 감지.In: 2016 International conference on inventive computing technologies(ICICT), vol 3. IEEE, pp 1 – 6 102. Zhang C, Wang H, Rongrong F(2013) 엔트로피 및 복잡도 측정을 기반으로 한 운전자 피로 자동 감지. IEEE Trans Intell Transp Syst 15(1):168 – 177 103. Nicolaou N, Georgiou J(2012) 순열 엔트로피와 지원 벡터 머신을 기반으로 한 간질성 뇌파 감지. Expert Syst Appl 39(1):202 – 209 104. Pincus SM(1991) 시스템 복잡성 측정을 위한 근사 엔트로피. Proc Natl Acad Sci 88(6):2297 – 2301 105. Zhang A, Yang B, Huang L(2008) 전력 스펙트럼 엔트로피를 사용한 EEG 신호의 특징 추출. In: 2008 international conference on BioMedical engineering and informatics, vol 2. IEEE, pp 435 – 439 106. Richman JS, Randall Moorman J (2000) 근사 엔트로피와 샘플 엔트로피를 사용한 생리학적 시계열 분석. Am J Physiol-Heart Circulat Physiol 278(6):H2039 – H2049 107. Lotte F, Congedo M, Lećuyer A, Lamarche F, Arnaldi B (2007) EEG 기반 뇌-컴퓨터 인터페이스를 위한 분류 알고리즘 검토. J Neural Eng 4(2):R1 108. Ayyagari SSDP, Jones RD, Weddell SJ (2021) EEG에서 마이크로 수면 상태 감지: 특징 감소 방법 비교. Med Biol Eng Comput 1 – 15 109. Fukunaga K(2013) 통계적 패턴 인식 소개.Elsevier, Amsterdam 110. Liu J, Meng H, Li M, Zhang F, Qin R, Nandi AK(2018) 지도 및 비지도 차원 축소를 기반으로 한 EEG 녹음으로부터의 감정 감지.Concurrency Comput: Pract Exp 30(23):e4446 111. Doma V, Pirouz M(2020) EEG 및 말초 생리 신호를 사용한 감정 인식을 위한 머신 러닝 방법의 비교 분석.J Big Data 7(1): 1 – 21 112. Abdulhamit Subasi M, Gursoy I(2010) pca, ica, lda 및 지원 벡터 머신을 사용한 EEG 신호 분류. Expert Syst Appl 37(12):8659 – 8666 113. Widodo A, Yang B-S(2007) 유도 전동기의 고장 진단을 위한 비선형 특징 추출 및 지원 벡터 머신의 적용.Expert Syst Appl 33(1):241 – 250 114. Mafarja M, Mirjalili S(2018) 래퍼 특징 선택을 위한 Whale 최적화 접근 방식.Appl Soft Comput 62:441 – 453 115. Cabrera AF, Farina D, Dremstrup K(2010) 비운동 이미지로 구동되는 뇌-컴퓨터 인터페이스를 위한 특징 선택 및 분류 방법 비교.Med Biol Eng Comput 48(2):123 – 132 116. Koprinska I(2009) 뇌-컴퓨터 인터페이스를 위한 특징 선택.In: Pacific-Asia conference on knowledge discovery and data mining. 스프링거, 106-117쪽 117. Kohavi R, John GH(1997) 기능 하위 집합 선택을 위한 래퍼.Artif Intell 97(1 – 2):273 – 324 118. Sabeti M, Boostani R, Katebi SD, Price GW(2007) 정신분열증 환자의 EEG 신호 분류를 위한 관련 기능 선택.Biomed Signal Process Control 2(2):122 – 134 119. John GH, Kohavi R, Pfleger K(1994) 무관한 기능 및 하위 집합 선택 문제.In: Machine learning procedures.Elsevier, pp 121 – 129 120. Langley P et al(1994) 기계 학습에서 관련 기능 선택. In: Proceedings of the AAAI Fall symposium on re- levance 184:245 – 271 121. Battiti R (1994) 지도 신경망 학습에서 피처 선택을 위한 상호 정보 사용.IEEE Trans Neural Networks 5(4):537 – 550 122. Peng H, Long F, Ding C(2005) 최대 종속성, 최대 관련성 및 최소 중복성의 상호 정보 기준에 따른 피처 선택.IEEE Trans Pattern Anal Mach Intell 27(8):1226 – 1238 123. Reunanen J(2003) 변수 선택 방법 간 비교 시 과적합.J Mach Learn Res 3:1371 – 1382 124. Pudil P, Novovičova ́J, Kittler J(1994) 피처 선택에서 플로팅 검색 방법. Pattern Recogn Lett 15 (11):1119 – 1125 125. Talbi E-G(2009) 메타휴리스틱: 설계에서 구현까지, 74권.Wiley, Hoboken 126. Fister Jr I, Yang X-S, Fister I, Brest J, Fister D(2013) 최적화를 위한 자연에서 영감을 받은 알고리즘에 대한 간략한 리뷰.arXiv 사전 인쇄본 arXiv:1307.4186 127. Zawbaa HM, Emary E, Parv B(2015) 개미사자 최적화 알고리즘을 기반으로 한 특징 선택.2015년 제3세계 복잡계 회의(WCCS).IEEE, pp 1 – 7 128. Emary E, Zawbaa HM, Hassanien AE(2016) 특징 선택을 위한 이진 회색 늑대 최적화 접근 방식. Neurocomputing 172:371 – 381 129. Mistry K, Zhang L, Neoh SC, Lim CP, Fielding B(2016) 지능형 얼굴 감정 인식을 위한 마이크로 GA 임베디드 PSO 기능 선택 접근법.IEEE Trans Cybern 47(6):1496 – 1509 130. Baig MZ, Aslam N, Shum HPH, Zhang L(2017) 운동 이미지 EEG에서 최적의 기능 하위 집합 선택을 위한 도구로서의 차등 진화 알고리즘.Expert Syst Appl 90:184 – 195 131. Kim KH, Bang SW, Kim SR(2004) 생리 신호의 단기 모니터링을 사용한 감정 인식 시스템.Med Biol Eng Compu 42(3):419 – 427 132. Ilyas MZ, Saad P, Ahmad MI(2015) 뇌-컴퓨터 인터페이스를 위한 EEG 신호의 분석 및 분류에 대한 조사. 2015년 제2회 국제 생체공학 컨퍼런스(ICoBE). IEEE, pp 1 – 6 133. Soleymani M, Lichtenauer J, Pun T, Pantic M(2011) 감정 인식 및 암묵적 태깅을 위한 다중 모달 데이터베이스.IEEE Trans Affect Comput 3(1):42 – 55 134. Ruo-Nan Duan, Jia-Yi Zhu, Bao-Liang Lu(2013) EEG 기반 감정 분류를 위한 차등 엔트로피 특징.2013년 제6회 국제 IEEE/EMBS 신경공학 컨퍼런스(NER).IEEE, pp 81 – 84 135. Katsigiannis S, Ramzan N(2017) Dreamer: 무선 저가형 기성품 장치의 EEG 및 ECG 신호를 통한 감정 인식을 위한 데이터베이스. IEEE J Biomed Health Inform 22(1):98 – 107 136. Miranda Correa JA, Khomami Abadi M, Sebe N, Patras I(2018) Amigos: 개인 및 그룹에 대한 정서, 성격 및 기분 연구를 위한 데이터 세트. IEEE Trans Affect Comput 137. Lan Z, Liu Y, Sourina O, Wang L, Scherer R, Mu ̈ller-Putz G(2020) Safe: 안정적인 정서적 특징 선택을 위한 eeg 데이터 세트. Adv Eng Inform 44:101047

138. Lv Z, Qiao L, Wang Q, Piccialli F(2020) 뇌-컴퓨터 인터페이싱을 위한 고급 머신 러닝 방법.IEEE/ACM Trans Comput Biol Bioinform 139. Drucker H, Donghui W, Vapnik VN(1999) 스팸 분류를 위한 지원 벡터 머신.IEEE Trans Neural Networks 10(5):1048 – 1054 140. Kumar S, Singh S, Kumar J(2018) haar 웨이블릿 특징과 svm을 사용한 유전 알고리즘을 사용한 자동 라이브 얼굴 표정 감지. Wireless Pers Commun 103(3):2435 – 2453 141. Kumar S, Singh S, Kumar J(2019) svm 분류기를 사용한 하이브리드 특징을 사용한 다중 얼굴 감지.In: 데이터 및 통신 네트워크. Springer, pp 253 – 265 142. Shi L, Wang X, Shen Y(2020) LBP 및 SVM 기반 3D 얼굴 인식 방법에 대한 연구. Optik 220:165157 143. Asuntha A, Brindha A, Indirani S, Srinivasan A(2016) SVM 알고리즘과 최적화 기술을 사용한 폐암 탐지. J Chem Pharm Sci 9(4):3198 – 3203 144. Dolatabadi AD, Khadem SEZ, Asl BM(2017) 최적화된 SVM을 사용한 관상동맥질환(CAD) 환자의 자동 진단. Comput Methods Programs Biomed 138:117 – 126 145. Nilash M, Ahmadi N, Samad S, Shahmoradi L, Ahmadi H, Ibrahim O, Asadi S, Abdullah R, Abumalloh RA, Yadegaridehkordi E(2020) 기계 학습 기술을 사용한 질병 진단: 검토 및 분류.Journal of Soft Computing and Decision Support Systems 7(1):19 – 30 146. Francis LM, Sreenath N(2020) 자연 장면에서 최소 제곱 svm을 사용한 Tedless 텍스트 감지.Journal of King Saud University-Computer and Information Sciences 32(3):287 – 299 147. Lin W, Ji D, Yanan L(2017) 다중 레이블 구조 svm을 사용한 임상 텍스트에서 장애 인식. BMC Bioinformatics 18(1):1 – 11 148. Hassan AKA, Mahdi BS, Mohammed AA(2019) 스케일 불변 특성 변환 및 지원 벡터 머신을 기반으로 한 아랍어 필기 단어 인식.이라크 Jf Sci 381 – 387 149. Shalev-Shwartz S, Ben-David S(2014) 머신 러닝 이해: 이론에서 알고리즘까지.케임브리지 대학교 출판부, 케임브리지 150. Chen W-H, Hsu S-H, Shen H-P(2005) 침입 탐지를 위한 svm 및 ann 응용.컴퓨터 및 운영 연구 32(10):2617 – 2634 151. Basheer IA, Hajmeer M(2000) 인공 신경망: 기본, 컴퓨팅, 설계 및 응용. J Microbiol Methods 43(1):3 – 31 152. Fausett LV(2006) 신경망의 기초: 아키텍처, 알고리즘 및 응용 프로그램.Pearson Education India 153. Sharma S, Sharma S(2017) 신경망의 활성화 함수.Towards Data Science 6(12):310 – 316 154. Quinlan JR(2014) C4. 5: 머신 러닝 프로그램.Elsevier 155. Loh W-Y(2011) 분류 및 회귀 트리.Wiley Interdiscip Rev: Data Min Knowl Discov 1(1):14 – 23 156. Bastos NS, Marques BP, Adamatti DF, Billa CZ(2020) 의사결정 트리를 사용하여 EEG 신호 분석: 진폭 변조에 대한 연구. Comput Intell Neurosci 157. Rasoul Safavian S, Landgrebe D(1991) 의사결정 트리 분류기 방법론 조사.IEEE Trans Syst Man Cybern 21(3):660 – 674 158. Rafik Khairul Amin, Yuliant Sibaroni 외(2015) 채무자의 대출 신청 의사결정에 c4.5 알고리즘을 사용한 의사결정 트리 구현(사례 연구: 요그야카르타 특별 지역의 Bank pasar). 2015년 제3회 정보통신기술 국제회의(ICoICT), 75 – 80쪽.IEEE 159. Ruggieri S(2002) 효율적인 c4.5 [분류 알고리즘].IEEE Trans Knowl Data Eng 14(2):438 – 444

160. Tin Kam Ho(1995) 랜덤 결정 포레스트. 제3회 문서 분석 및 인식 국제 컨퍼런스의 회의록, 제1권.IEEE, 278-282쪽 161. Değer Ayata, Yusuf Yaslan, Mustafa Kamaşak(2016) 랜덤 포레스트와 전기 피부 반응을 통한 감정 인식: 시간 기반 특징 세트, 윈도우 크기 및 웨이블릿 접근 방식 비교.2016년 의료 기술 전국 회의(TIPTEKNO).IEEE, 1-4쪽 162. Breiman L(2001) 랜덤 포레스트.Mach Learn 45(1):5-32 163. Peterson LE(2009) K-최근접 이웃. Scholarpedia 4(2):1883 164. Pascal Soucy, Guy W Mineau(2001) 텍스트 분류를 위한 간단한 knn 알고리즘.In: Proceedings 2001 IEEE 국제 데이터 마이닝 컨퍼런스.IEEE, pp 647 – 648 165. Fatemeh Bahari, Amin Janghorbani(2013) 재귀 플롯 분석 및 k 최근접 이웃 분류기를 사용한 Eeg 기반 감정 인식.2013년 제20회 이란 생체공학 컨퍼런스(ICBME).IEEE, pp 228 – 233 166. Sasirekha K, Thangavel K(2019) 얼굴 인식을 위한 입자 군집 최적화를 사용한 k-최근접 이웃 최적화. Neural Comput Appl 31(11):7935 – 7944 167. Wang H, Zhang Y et al(2016) naive bayes 기반 학습 프로세스를 활용한 운동 이미지 EEG 신호 감지. 측정 86:148 – 158 168. M Wiggins, Ashraf Saad, Brian Litt 및 George Vachtsevanos. 의료 응용 분야에서 ecg 기반 연령 분류를 위한 베이지안 분류기 개발. 응용 소프트 컴퓨팅, 8(1):599 – 608, 2008 169. Sharmila A, Geethanjali P(2016) naive bayes 및 k-nn 분류기를 사용하여 EEG 신호에서 간질 발작을 DWT 기반으로 감지. Ieee Access 4:7716 – 7727 170. Dong S, Wang P, Abbas K(2021) 딥러닝과 그 응용에 대한 조사.Computer Science Review 40:100379 171. Iqbal H Sarker. 딥러닝: 기술, 분류법, 응용 프로그램 및 연구 방향에 대한 포괄적인 개요.SN Computer Science, 2(6):1 – 20, 2021 172. Fukushima K(1980) 위치 이동에 영향을 받지 않는 패턴 인식 메커니즘을 위한 자기 조직화 신경망 모델.Biol Cybern 36:193 – 202 173. Hinton GE, Salakhutdinov RR(2006) 신경망을 사용하여 데이터의 차원 감소. science 313(5786):504 – 507 174. Yoshua Bengio, Pascal Lamblin, Dan Popovici, Hugo Larochelle(2007) 심층 네트워크의 탐욕적 계층별 학습. 신경 정보 처리 시스템의 발전, pp 153 – 160 175. Pascal Vincent, Hugo Larochelle, Isabelle Lajoie, Yoshua Bengio, Pierre-Antoine Manzagol, León Bottou(2010) 스택된 노이즈 제거 자동 인코더: 로컬 노이즈 제거 기준을 사용하여 심층 네트워크에서 유용한 표현 학습. 기계 학습 연구 저널, 11(12) 176. Chamara L, Zhou H, Huang GB, Vong CM(2013) 빅데이터를 위한 익스트림 러닝 머신을 사용한 표현 학습. IEEE Intell Syst 28(6):31 – 34 177. Chen M, Weinberger KQ, Zhixiang X, Sha F(2015) 스택형 선형 노이즈 제거 자동 인코더의 주변화.The Journal of Machine Learning Research 16(1):3849 – 3875 178. Cao J, Zhao Y, Lai X, Ong MEH, Yin C, Koh ZX, Liu N(2015) 희소 표현 분류 및 극단 학습 머신을 통한 랜드마크 인식.J Franklin Inst 352(10):4528 – 4545 179. Cao J, Zhang K, Luo M, Yin C, Lai X(2016) 이미지 분류를 위한 극단 학습 머신 및 적응형 희소 표현. Neural Netw 81:91 – 102 180. Yang Y, Wu QMJ(2015) 표현 학습을 위한 서브네트워크 노드가 있는 다층 극단 학습 머신. IEEE 사이버네틱스 거래 46(11):2570 – 2583

181. Zhang J, Wu Y(2018) 복소수 값 합성 신경망을 사용한 단일 채널 EEG의 자동 수면 단계 분류.생체공학/생체의학기술 63(2):177 – 190 182. Jiao Y, Deng Y, Luo Y, Bao-Liang L(2020) GAN 및 LSTM 네트워크를 사용하여 EEG 및 EOG 신호에서 운전자 졸음 감지.Neurocomputing 408:100 – 111 183. Soumalya Sarkar, Kishore Reddy, Alex Dorgan, Cali Fidopiastis, Michael Giering(2016) 딥러닝을 통한 PHM 관련 서비스 환경에서의 웨어러블 EEG 기반 활동 인식.국제예후 및 건강관리저널, 7(4) 184. Maiorana E(2020) EEG 기반 생체 인식을 위한 딥러닝. Neurocomputing 410:374 – 386 185. Guo J (2013) 시간에 따른 역전파.미공개 논문.하얼빈 공업 대학 40:1 – 6 186. Sepp Hochreiter, Yoshua Bengio, Paolo Frasconi, Jurgen Schmidhuber 외 (2001) 순환 네트워크의 그래디언트 흐름: 장기 종속성 학습의 어려움 187. Reddy BK, Delen D (2018) 루푸스 환자의 재입원 예측: rnn-lstm 기반 딥러닝 방법론.Comput Biol Med 101:199 – 209 188. Hochreiter S, Schmidhuber J (1997) 장기 단기 기억. Neural Comput 9(8):1735 – 1780 189. Yamashita R, Nishio M, Do RKG, Togashi K(2018) 합성 신경망: 방사선학에서의 개요 및 응용.Insights Imaging 9(4):611 – 629 190. Alarcao SM, Fonseca MJ(2017) EEG 신호를 사용한 감정 인식: 조사.IEEE Trans Affect Comput 10(3):374 – 393 191. Harsh Dabas, Chaitanya Sethi, Chirag Dua, Mohit Dalawat, Divyashikha Sethia(2018) EEG 신호를 사용한 감정 분류. 2018년 2회 컴퓨터 과학 및 인공 지능 국제 컨퍼런스 논문집, 380-384쪽, 192쪽. Gao Y, Jong Lee H, Mehmood RM(2015) 감정 인식을 위한 EEG 신호의 심층 학습. 2015 IEEE 멀티미디어 및 엑스포 워크숍 국제 컨퍼런스(ICMEW)에서. IEEE, 1-5쪽 193쪽. Aya Hassouneh AM, Mutawa MM(2020) 얼굴 표정을 이용한 실시간 감정 인식 시스템 개발 및 머신 러닝 및 딥 신경망 방법을 기반으로 하는 eeg.Informatics in Medicine Unlocked 20:100372 194. Cui H, Aiping Liu X, Zhang XC, Wang K, Chen X(2020) 엔드투엔드 지역 비대칭 합성곱 신경망을 사용한 eeg 기반 감정 인식.Knowl-Based Syst 205:106243 195. Huang D, Chen S, Liu C, Zheng L, Tian Z, Jiang D(2021) 비대칭 뇌의 차이점: eeg 감정 인식을 위한 양반구 불일치 합성곱 신경망.Neurocomputing 448:140 – 151 196. Alhagry S, Fahmy AA, El-Khoribi RA(2017) lstm 순환 신경망을 사용한 eeg 기반 감정 인식. Emotion 8(10):355 – 358 197. Salama ES, El-Khoribi RA, Shoman ME, Wahby Shalaby MA(2018) 3차원 합성 신경망을 이용한 Eeg 기반 감정 인식.Int J Adv Comput Sci Appl 9(8):329 – 337 198. Kung FYH, Chao MM(2019) 협상에서 혼합된 감정이 창의성에 미치는 영향: 대인 관계적 관점.Front Psychol 9:2660 199. Zheng W(2016) 그룹 희소 정준 상관 분석을 통한 다중채널 EEG 기반 감정 인식.IEEE Transac- tions on Cognitive and Developmental Systems 9(3):281 – 290 200. Hadjidimitriou SK, Hadjileontiadis LJ(2012) 시간-주파수 분석을 이용한 음악 선호도의 EEG 기반 인식을 향하여. IEEE Trans Biomed Eng 59(12):3498 – 3510 201. Jenke R, Peer A, Buss M(2014) EEG에서 감정 인식을 위한 특징 추출 및 선택.IEEE Trans Affect Comput 5(3):327 – 339 202. Chatterjee R, Tanmoy Maitra SK, Islam H, Hassan MM, Alamri A, Fortino G(2019) 사물 인터넷 환경에서 운동 이미지 EEG 신호 분류를 위한 새로운 머신 러닝 기반 특징 선택.Futur Gener Comput Syst 98:419 – 434 203. Moreira MWL, Rodrigues JJPC, Kumar N, Saleem K, Illin IV(2019) 감정 인식 스마트 시스템을 위한 임신 데이터 분석을 통한 산후 우울증 예측.Information Fusion 47:23 – 31